WEB MINING · MAESTRÍA EN CIENCIA DE DATOS

¿Cómo nos cuentan las noticias?

Un monitor automático de 46 medios argentinos: agenda, tono y estilo de titulación

Integrantes: [completar] · Octubre 2026

EL PROBLEMA

Un mismo día, contado de 46 maneras distintas

- ¿De qué se habla hoy y qué crece respecto de lo habitual?
- ¿Qué medios cubren un tema o una persona, y con qué tono?
- ¿Qué noticias cubre todo el ecosistema y cuáles son exclusivas?
- ¿Quién titula de forma más alarmista o con más clickbait?
- ¿Cuánto contenido está firmado y cuánto sale como "Redacción"?

≈3.000

titulares por corrida, de 46 medios, cada media hora

Leerlos a mano es inviable: hay que extraerlos, estructurarlos y medirlos de forma automática.

LA SOLUCIÓN

Un monitor que corre solo, cada 30 minutos, y publica todo

46

medios: diarios, portales, TV, radios y fuentes oficiales

5.302

notas en la base, con tema, tono, entidades y estilo de título

24/7

GitHub Actions cada 30 minutos; tablero y base SQL publicados en GitHub Pages

Web mining de punta a punta: crawling de feeds, scraping de cada nota, procesamiento de lenguaje con BERT, base de datos histórica e indicadores comparables entre medios.

ARQUITECTURA

Seis etapas, de los feeds al tablero

1

Feeds

RSS y Google News de 46 medios, en paralelo

→

2

Validación

Descarta no-notas, fechas imposibles y duplicados

→

3

Scraping

Entra a cada nota: bajada y JSON-LD

→

4

Lenguaje

Tema, entidades, tono con BERT, cebo

→

5

SQLite

Histórico de 90 días, CSV exportable

→

6

Tablero

8 pestañas + SQL en el navegador

Automatización: GitHub Actions corre el pipeline cada 30 minutos, guarda la base en una rama de datos y publica el tablero en GitHub Pages. La primera corrida con BERT tarda 10 minutos; las siguientes, 2.

FUENTES

Dos vías para llegar a 46 medios sin claves ni costo

RSS propio — 17 medios

- Feed XML del medio: título, enlace, fecha y bajada
- La vía más limpia y estable
- Clarín, Infobae, La Nación, La Capital, TN…

Google News por sitio — 29 medios

- Búsqueda site:dominio de las últimas 48 h
- Cubre los medios sin RSS útil
- Pero devuelve una URL de Google y sin bajada

3.724 de 5.302 notas llegaron por Google News: sin el paso siguiente, solo tendríamos su título.

SCRAPING

Entramos a cada nota para leer lo que el RSS no trae

100%

de las notas analizadas entrando a su página

87%

con bajada (el resumen del propio medio)

Del HTML de cada nota extraemos

- **URL real:** decodificando el enlace de Google News
- **Bajada:** meta og:description o primer párrafo real
- **Autor y firma:** persona o "Redacción", desde el JSON-LD
- **Sección y palabras clave:** como las clasifica el propio medio
- **Largo del cuerpo:** cantidad de palabras de la nota

ÉTICA DESDE EL DISEÑO

Un crawler "bien educado", como pide la teoría

robots.txt

Se lee por dominio antes de pedir una nota. 0 bloqueos en 5.548 pedidos.

Nos identificamos

User-Agent propio que enlaza al proyecto: monitor-de-medios/1.0

Carga acotada

Máximo 2 pedidos a la vez por sitio y topes de notas y tiempo por corrida.

Sin insistir

Reintentos con espera creciente; una nota que falla dos veces no se vuelve a pedir.

No guardamos el texto completo de las notas: solo título, bajada y metadatos, siempre con enlace al original.

La web cambia: el scraper se vigila a sí mismo

Síntoma	Causa	Solución
Bajadas con código JavaScript	El respaldo de "primer párrafo" tomaba <path o código de un carrusel	Solo <p> reales, sin scripts; se descarta texto con forma de código
""" en el texto	Sitios que escapan las entidades dos veces	Doble decodificación de entidades HTML
"podrÃ¡" en vez de "podrá"	Páginas UTF-8 sin charset leídas como Latin-1	Forzar UTF-8 y reparar los tramos rotos
Medio caído o degradado	Feed vacío o con menos de la mitad de lo habitual	Tabla salud y alerta en el tablero

PROCESAMIENTO DE TEXTO

Cada nota recibe tema, entidades, tono y cebo



Temas

15 temas. Reglas sobre título + bajada, y un Naive Bayes que aprende de lo que las reglas ya clasificaron (supervisión débil).

"Otros": 24% → menos del 5%



Entidades

35 personas, instituciones y clubes con sus alias y reglas de desambiguación ("Banco Central" no es Rosario Central).

Más mencionados: Milei, Messi, el papa



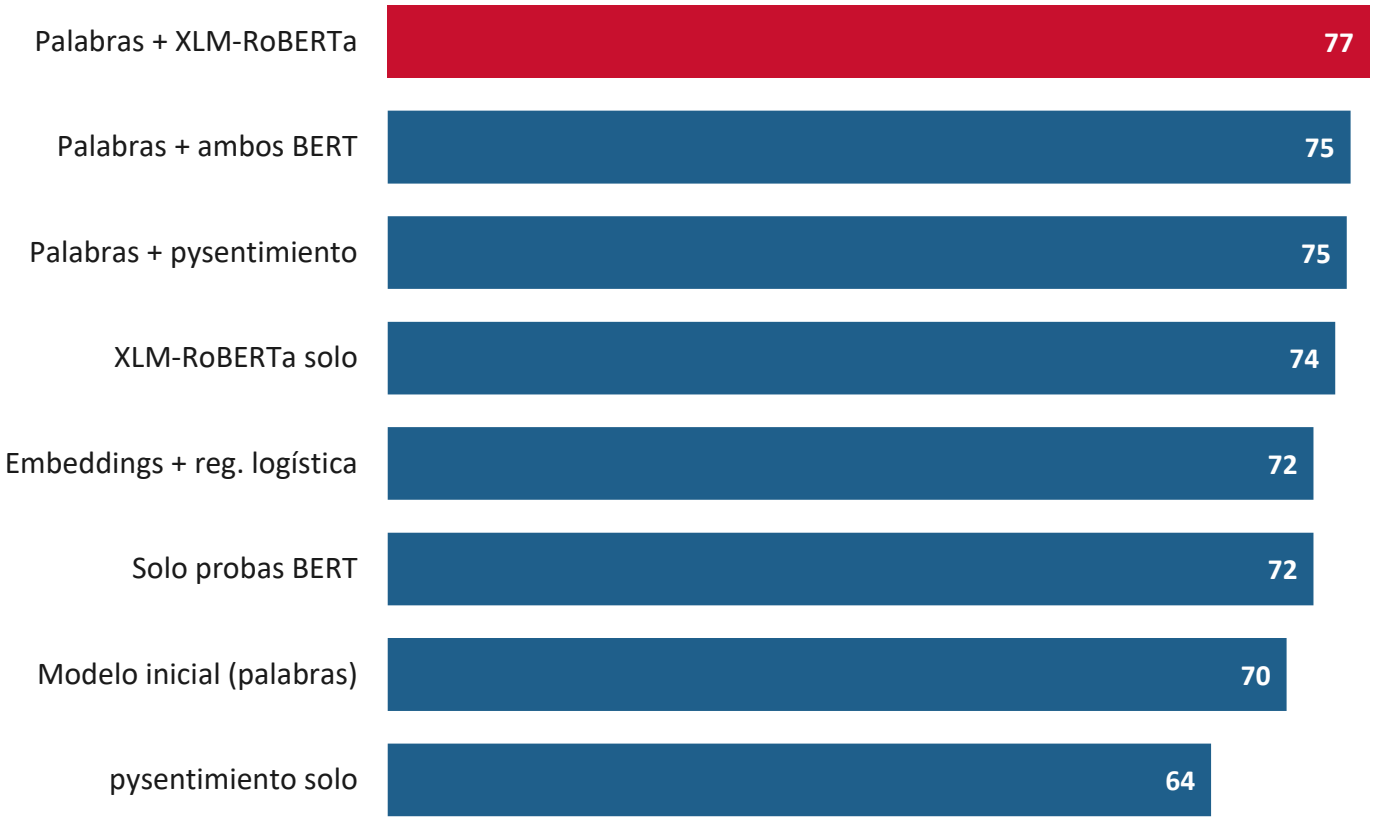
Tono

Si el hecho es bueno o malo para los involucrados. Palabras + probabilidades de BERT, sobre el título y sobre la bajada.

77% de acierto con validación cruzada

TONO CON BERT

Combinar palabras con BERT sube el acierto de 70% a 77%



77%

de acierto (antes 70%), medido con notas que el modelo no vio

84%

de las notas negativas detectadas (antes 65%)

MÁS ALLÁ DEL DICCIONARIO

El sistema aprende lo que no le enseñamos



Figuras nuevas (NER)

spaCy detecta personas e instituciones que no están en el diccionario y marca las que irrumpen hoy en la agenda.

Ej.: Fundación Faro, Gonzalo Belloso



Búsqueda por significado

Embeddings MiniLM: notas parecidas de otros medios aunque no compartan palabras, y búsqueda semántica en el navegador.

"Murió una joven embarazada…" ↔ La Voz: 0,85

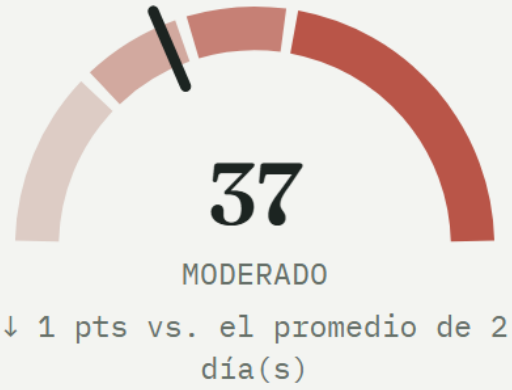


Aprendizaje activo

El modelo de tono eligió los 60 titulares donde más dudaba; los etiquetamos a mano y reentrenamos.

Resultado: 76% → 76%; eran casos ambiguos

Un termómetro y un resumen que se escriben solos



RESUMEN DEL DÍA

En las últimas 24 horas, **45 medios** publicaron **1.684 notas**. El tema más cubierto fue **Política** (21% de las notas), seguido por Seguridad y justicia. La noticia que más medios cubrieron fue «**La Justicia sobreseyó a Javier y Karina Milei en la causa $Libra**» (12 medios; la publicó primero El Cronista). La figura más mencionada fue **Javier Milei** (97 notas, ≈46% con tono negativo). El medio más negativo fue **Aire de Santa Fe** (≈48%) y el menos negativo, **Olé** (≈21%). El que más veces llegó primero a una historia compartida fue **Eldoce** (19 veces). El termómetro de negatividad marca **37 (moderado)**.

Termómetro: % de notas negativas de las últimas 24 h (calmo, moderado, tenso, muy tenso).

Resumen: redactado con plantillas a partir de los datos del día; sin modelo de lenguaje, reproducible.

Tres indicadores para medir el estilo, no solo el contenido

1 **Exageración**

El título es negativo y la bajada del propio medio no lo es.

"El dramático relato…" → bajada: datos del vuelo y los pasajeros

2 **Cebo (clickbait)**

Preguntas, exclamaciones, adjetivos exagerados, intriga, segunda persona, listas.

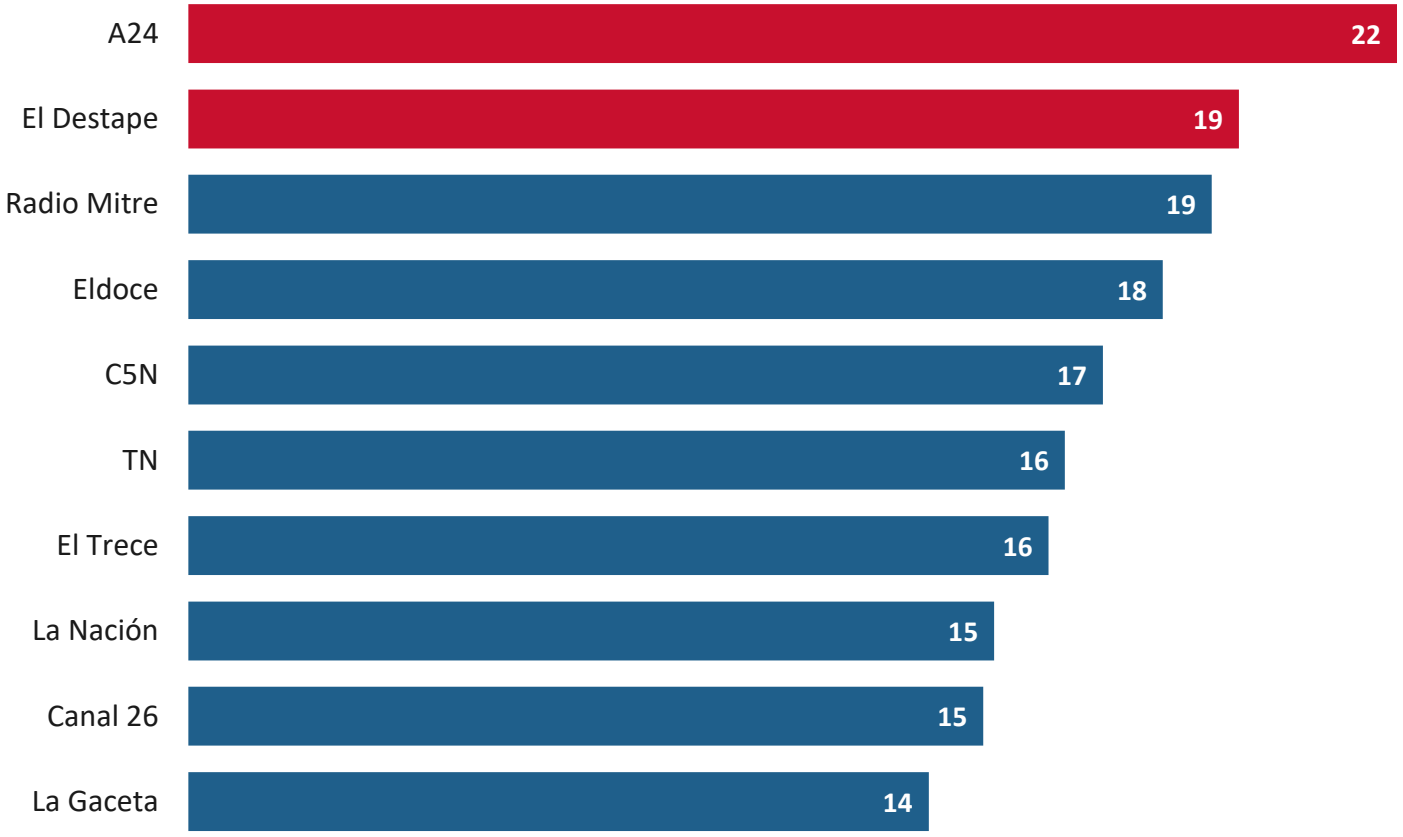
"¡Escándalo! Aseguran que…" · "El truco viral para…"

3 **Transparencia**

Notas firmadas por un periodista, según los datos estructurados de la nota.

"Redacción" o el nombre del medio no cuentan como firma

A24 y El Destape usan recursos de cebo en casi 1 de cada 5 títulos

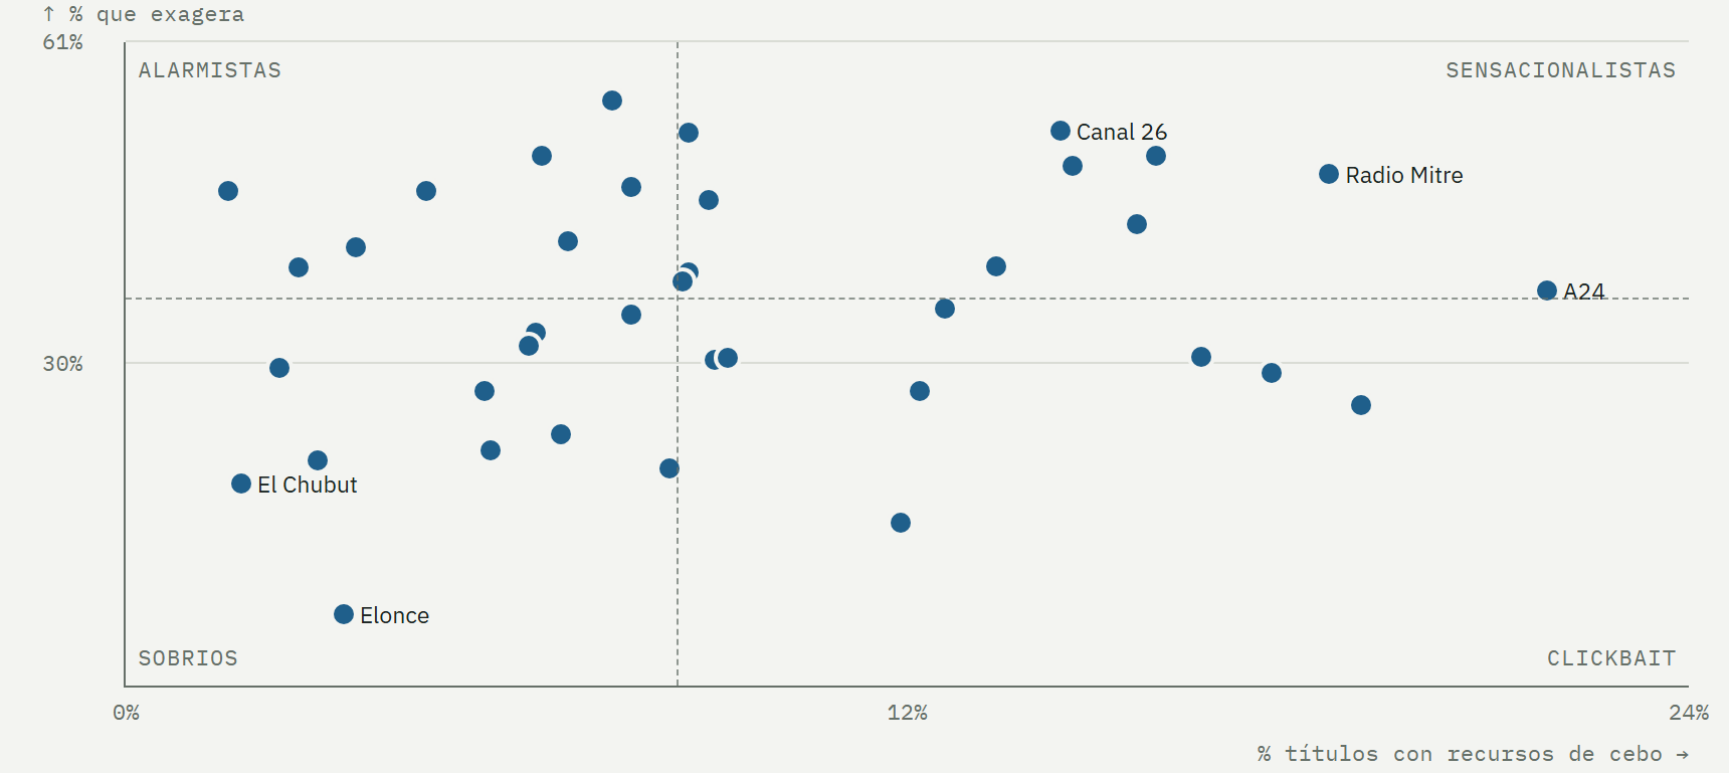


En el otro extremo

- Perfil: 1,6%
- El Chubut: 1,8%
- Rosario Nuestro: 2,4%
- La Capital: 2,7%

Porcentaje de títulos con al menos un recurso de cebo; medios con 40 notas o más.

El mapa: quién exagera y quién busca el clic

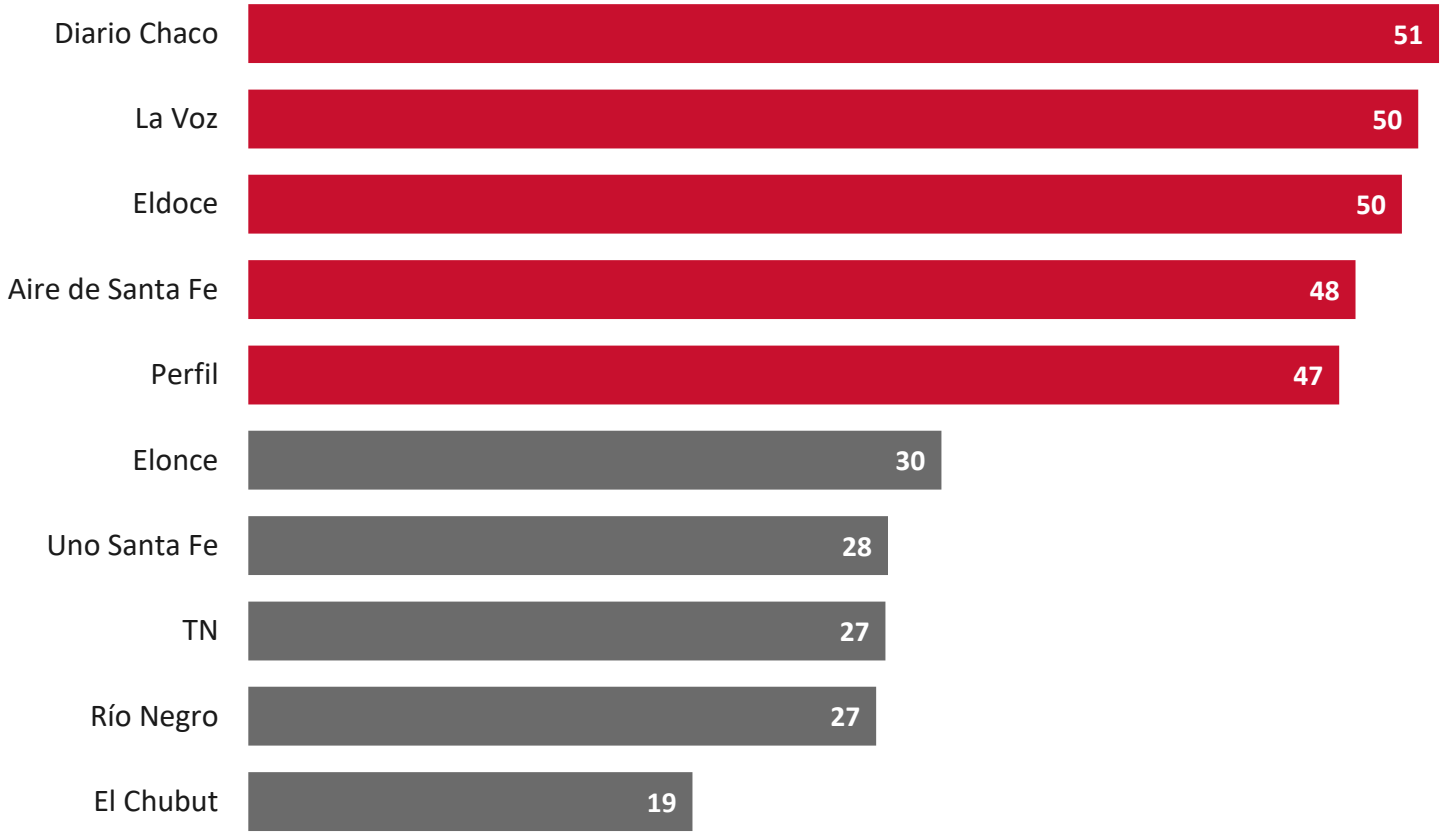


Cómo leerlo

Arriba a la derecha: títulos con cebo que además exageran.

Abajo a la izquierda: títulos sobrios y fieles a su bajada.

En Diario Chaco, 1 de cada 2 notas es negativa; en El Chubut, 1 de cada 5



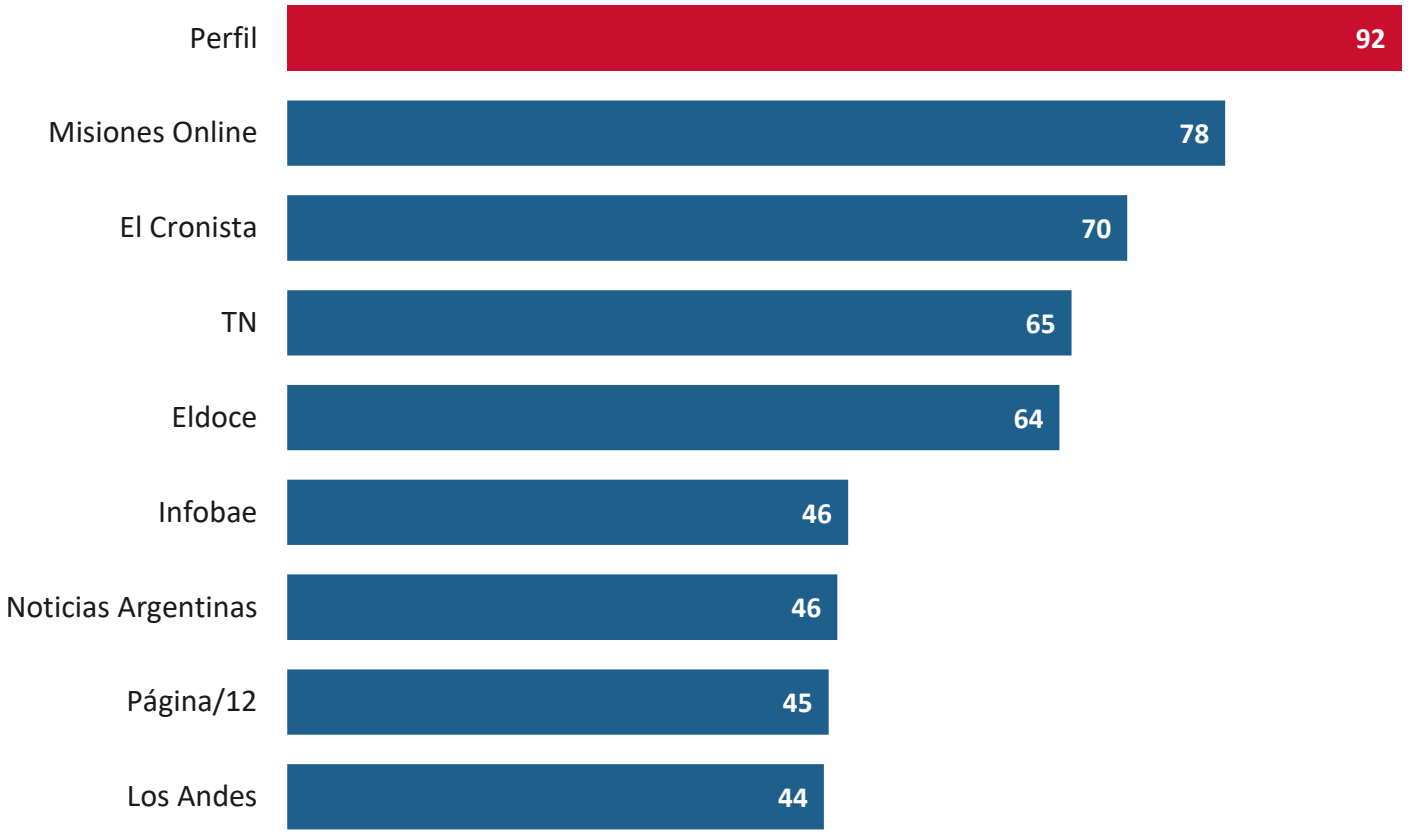
En toda la base

39% Negativo

49% Neutro

13% Positivo

Perfil firma el 92% de sus notas; Radio Mitre y Rosario3, ninguna



Sin ninguna nota firmada

- Elonce
- La Capital (Mar del Plata)
- Radio Continental
- Radio Mitre
- Rosario Nuestro
- Rosario3

Una noticia, muchos encuadres



Quién llega primero

Medio que más veces publicó primero una historia que después cubrieron otros:

Eldoce

Cada tarjeta muestra el tono del título, sus recursos de cebo y los minutos de demora respecto del primero.

TONO POR FIGURA

Cómo trata cada medio a cada figura

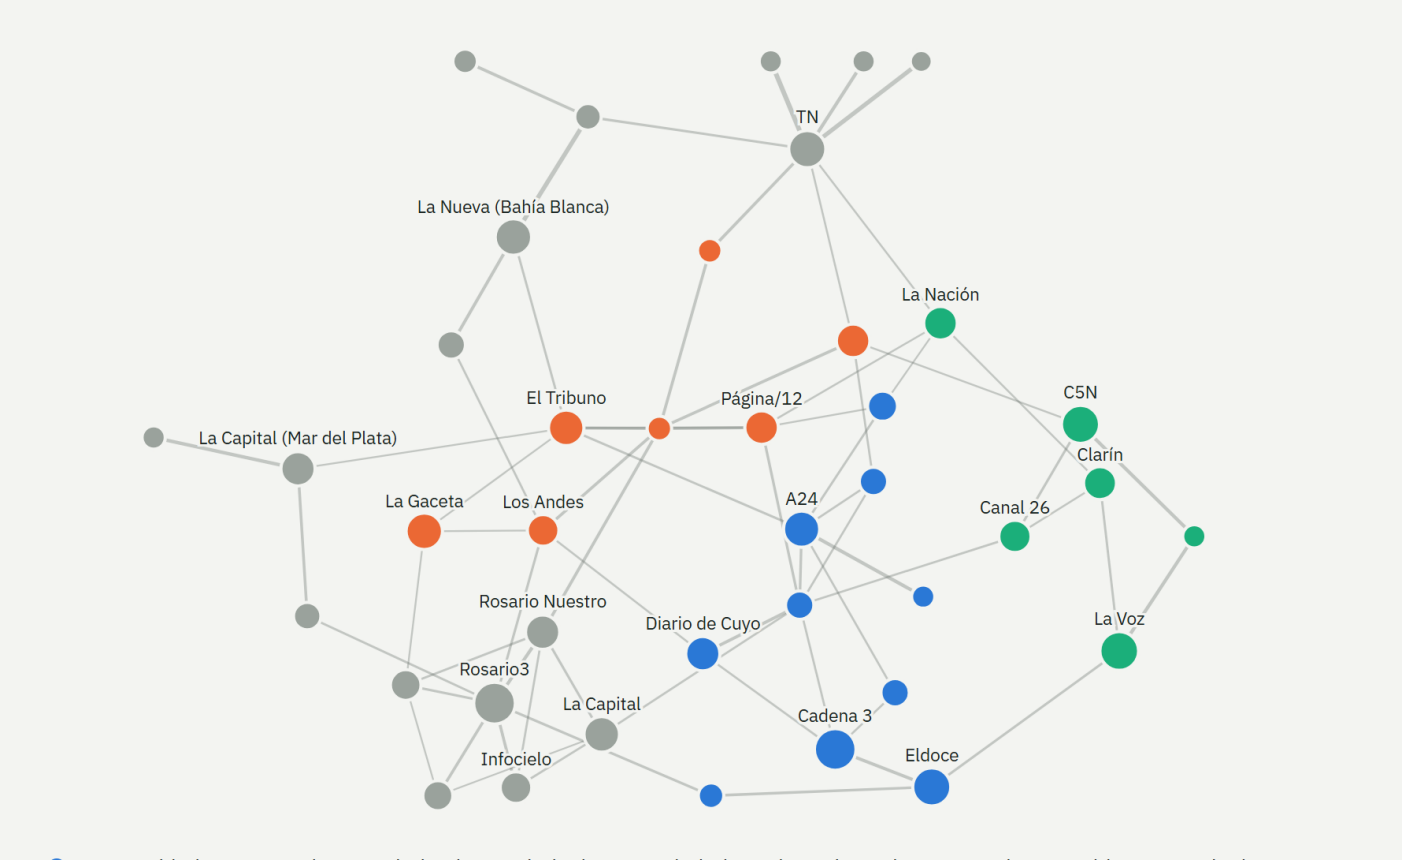
	Javier Milei	Lionel Messi	Papa León XIV	Policía	Rosario Central	Donald Trump	Boca
Infobae	73% (8)	·	·	81% (14)	·	26% (5)	·
Elonce	·	·	33% (3)	·	·	·	·
TN	47% (6)	·	·	·	·	·	10% (3)
Clarín	39% (10)	8% (5)	·	·	·	56% (14)	·
La Nación	51% (7)	·	·	·	·	·	·
Radio Mitre	26% (5)	3% (4)	18% (9)	80% (3)	·	·	·
El Litoral	7% (3)	6% (5)	·	·	·	·	·

Rojo: más negativo que el promedio de los medios con esa figura.

Verde: menos negativo.

Entre paréntesis, la cantidad de notas.

El mapa de medios: quién comparte agenda con quién



Cómo se arma

- Nodos: medios; tamaño según historias compartidas
- Aristas: cubren las mismas historias
- Colores: comunidades detectadas por propagación de etiquetas
- Disposición por fuerzas, animada en el tablero

Todo esto, en un tablero público que se actualiza solo



Resumen
termómetro, resumen del día y noticias compartidas

Titulares
buscador por texto o por significado y notas parecidas

Monitor
figuras nuevas (NER) y seguimiento de una persona

Análisis
filtros, agenda, encuadre y mapa de medios

Cómo titulan
mapa, rankings y ejemplos

Salud de datos
fuentes y scraping

DEMO EN VIVO

La base se consulta con SQL desde el navegador

```
SELECT medio,
  ROUND(100*AVG(cebo>=1), 1) AS cebo,
  ROUND(100*AVG(tono_auto='n'), 1) AS neg
FROM items
GROUP BY medio
HAVING COUNT(*) >= 50
ORDER BY cebo DESC;
```

1. Abrir el tablero (QR al final)
2. Tocar "Explorar la base (SQL)"
3. Elegir la tabla items o escribir una consulta
4. Descargar la base o el CSV si se quiere

HERRAMIENTAS

Un stack simple, gratuito y reproducible

Recolección

requests · feedparser · googlenewsdecoder · urllib.robotparser

Extracción

expresiones regulares · JSON-LD (schema.org) · HTML

Lenguaje

bolsa de palabras · Naive Bayes · regresión logística · XLM-RoBERTa · MiniLM · spaCy (NER)

Datos

SQLite · CSV · Datasette Lite · notebook con pandas

Automatización

GitHub Actions (cada 30 min, autodisparo) · pruebas automáticas

Visualización

HTML, CSS y JavaScript sin frameworks · GitHub Pages

LO QUE SIGUE

Limitaciones honestas y próximos pasos

Limitaciones

- Tono del título y la bajada, no de la nota completa
- 77% de acierto con 340 etiquetas de un solo criterio
- Pocos días de histórico: los rankings se estabilizan con semanas
- Temas y entidades por diccionario requieren mantenimiento

Próximos pasos

- Completar rondas de aprendizaje activo y medir la mejora
- Evolución de las comunidades a lo largo de las semanas
- Con más días: ¿el tono acompaña al dólar?
- Más etiquetas manuales, con varios anotadores

PROBALO AHORA

Gracias

Escaneá el código para abrir el tablero y consultar la base con SQL

miguegarrone-blip.github.io/Web-Mining

Código: github.com/miguegarrone-blip/Web-Mining