EDICIÓN ESPECIAL
Web Mining
Grupo 3

La Tapa

El diario que lee a los diarios

46 MEDIOS
84.040 notas
cada 30 minutos

ROSARIO, VIERNES 6 DE NOVIEMBRE DE 2026 · EDICIÓN ESPECIAL · WEB MINING · GRUPO 3 · AÑO 1 · N.º 1 · PRECIO: UNA PREGUNTA

MAESTRÍA EN CIENCIA DE DATOS · WEB MINING

¿Cómo nos cuentan las noticias?

Un monitor automático lee 46 medios argentinos cada media hora y mide de qué hablan, con qué tono y cómo titulan.

Por Grupo 3: Martín Ceriotti · Miguel Garrone · Lucía Tamplin · Milagros Terán

Docentes: Enrique Fernández · Héctor E. Giorgiutti

UNIVERSIDAD AUSTRAL · SEDE ROSARIO · 2026

HOY EN LOS MEDIOS

INFOBAE · 12:32

Milei llega a Madrid para asistir a la Cumbre Iberoamericana

C5N · 16:16

El papa León XIV recibió a Bob Dylan en el Vaticano mientras prepara su gira en Sudamérica

INFOCIELO · 09:47

Murió en La Plata Elsa Pavón, cofundadora de “Abuelas” y la primera en recuperar a su nieta

EL PROBLEMA

Un mismo día, contado de 46 maneras

La historia más compartida de los últimos tres días llegó a 22 medios. Y cada media hora entran ≈3.000 titulares: nadie puede leerlos a mano.

CANAL 26 · 07:50 · PRIMERO
Cristiano Ronaldo anunció su retiro de la Selección de Portugal

LA GACETA · 07:58 · +8 min
Cristiano Ronaldo anunció su retiro de la Selección de Portugal después de 23 años

DIARIO CHACO · 08:05 · +15 min
Fin de una era: Cristiano Ronaldo anunció su retiro de la selección de Portugal después de 23 años

OLÉ · 08:06 · +16 min
Cristiano Ronaldo anuncia su retiro de la selección de Portugal

NOTICIAS ARGENTINAS · 08:30 · +40 min
Fin de una era: Cristiano Ronaldo anunció su retiro de la selección de Portugal tras 23 años

ELDOCE · 08:35 · +45 min
Cristiano Ronaldo anunció su retiro de la selección de Portugal tras 23 años

SUMARIO: CINCO PREGUNTAS

1. ¿De qué se habla hoy y qué crece respecto de lo habitual?
2. ¿Qué medios cubren un tema o una persona, y con qué tono?
3. ¿Qué noticias cubre todo el ecosistema y cuáles son exclusivas?
4. ¿Quién titula de forma más alarmista o con más clickbait?
5. ¿Cuánto contenido está firmado y cuánto sale como «Redacción»?

LA SOLUCIÓN

Un monitor que corre solo, cada 30 minutos, y publica todo

Tres cifras para fijar la escala del trabajo.

46

medios: diarios, portales, TV, radios y fuentes oficiales

84.040

notas en la base, cada una con tema, tono, entidades y estilo de título

626

corridas automáticas en GitHub Actions; tablero y base SQL publicados en GitHub Pages

> *Web mining de punta a punta: crawling de feeds, scraping de cada nota, procesamiento de lenguaje con BERT, base histórica e indicadores comparables entre medios.*

INFOGRAFÍA

Seis etapas, de los feeds al tablero

El recorrido de cada nota, de izquierda a derecha. El paso 3 es el que convierte esto en web mining.



1 Feeds

RSS y Google News de 46 medios, en paralelo

2 Validación

Descarta no-notas, fechas imposibles y duplicados

3 Scraping

Entra a cada nota: bajada y JSON-LD

4 Lenguaje

Tema, entidades, tono con BERT y cebo

5 SQLite

Base histórica y CSV exportable

6 Tablero

Pestañas + SQL en el navegador

GITHUB ACTIONS — corre el pipeline cada 30 minutos, guarda la base en una rama de datos y publica el tablero en GitHub Pages. La primera corrida con BERT tarda 10 minutos; las siguientes, 2.

FUENTES

Dos vías para llegar a 46 medios sin claves ni costo

Las APIs de noticias limitan pedidos y no cubren medios regionales: combinamos RSS propio con Google News por sitio.

17 MEDIOS

RSS propio

- Feed XML del medio: título, enlace, fecha y bajada
- La vía más limpia y estable
- Clarín, Infobae, La Nación, La Capital, TN…

29 MEDIOS

Google News por sitio

- Búsqueda site:dominio de las últimas 48 horas
- Cubre los medios sin RSS útil
- Pero devuelve una URL de Google y sin bajada

29.243 de 84.040 notas vienen de medios que solo llegan por Google News: sin el paso siguiente, de ellas solo tendríamos el título.

SCRAPING

Entramos a cada nota para leer lo que el RSS no trae

Los feeds son páginas de listado; cada nota es una página de detalle, con su bajada y sus datos estructurados.

100%

de las notas analizadas entrando a su página

80%

con bajada: el resumen escrito por el propio medio

DEL HTML DE CADA NOTA

URL real
decodificando el enlace de Google News

Bajada
meta og:description o primer párrafo

Autor y firma
persona o «Redacción», del JSON-LD

Sección y claves
como las clasifica el propio medio

Largo
cantidad de palabras del cuerpo

```
<script type="application/ld+json">
{
  "@type": "NewsArticle",
  "headline": "Cristiano Ronaldo…",
  "author": {
    "@type": "Person",
    "name": "…"
  },
  "articleSection": "Deportes",
  "wordCount": 412
}
```

JSON-LD: LO QUE EL DIARIO LE DICE A GOOGLE

ÉTICA DESDE EL DISEÑO

Un crawler «bien educado», como pide la teoría

Cuatro reglas que el sistema cumple en cada corrida, como un reglamento de la casa.

ART. 1

robots.txt

Se lee por dominio antes de pedir una nota: 1 bloqueo en 85.642 pedidos.

ART. 2

Nos identificamos

User-Agent propio que enlaza al proyecto: monitor-de-medios/1.0.

ART. 3

Carga acotada

Máximo 2 pedidos a la vez por sitio y topes de notas y de tiempo por corrida.

ART. 4

Sin insistir

Reintentos con espera creciente; una nota que falla dos veces no se vuelve a pedir.

No guardamos el texto completo de las notas: solo título, bajada y metadatos, siempre con enlace al original.

PROCESAMIENTO DE TEXTO

Cada nota recibe tema, entidades, tono y cebo

Bolsa de palabras y modelo vectorial como base; un titular real, tal como lo procesa el sistema.

INFOBAE · 15:33

Argentina restringirá vuelos durante la visita papal y refuerza vigilancia militar

→

TEMA Transporte y ciudad

ENTIDADES Papa León XIV

TONO negativo

CEBO ninguno

Temas

15 temas. Reglas sobre título + bajada, y un Naive Bayes que aprende de lo que las reglas ya clasificaron (supervisión débil).

«OTROS»: DE 24% A MENOS DE 5%

Entidades

Personas, instituciones y clubes con sus alias y reglas de desambiguación («Banco Central» no es Rosario Central).

MÁS MENCIONADO: JAVIER MILEI

Tono

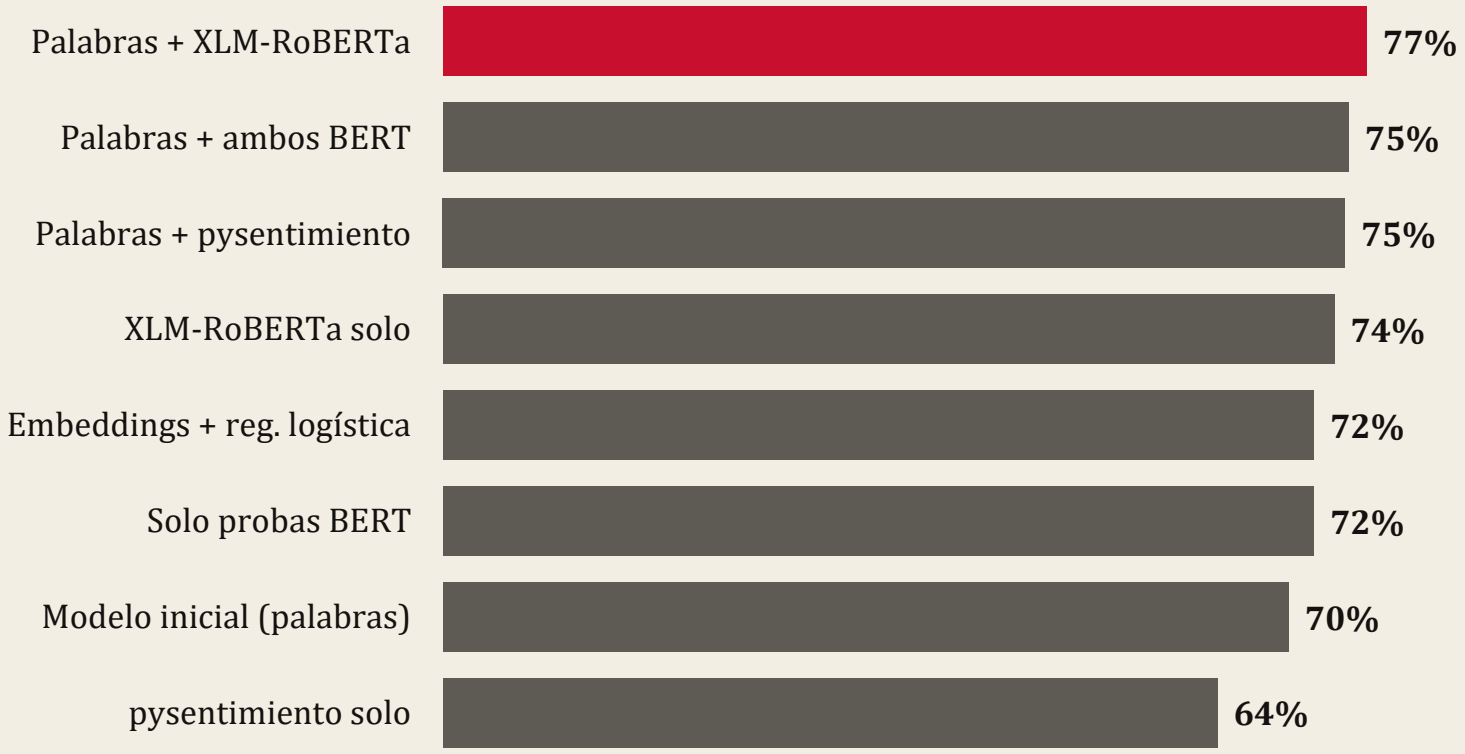
Si el hecho es bueno o malo para los involucrados. Palabras + probabilidades de BERT, sobre el título y sobre la bajada.

77% DE ACIERTO CON VALIDACIÓN CRUZADA

TONO CON BERT

Combinar palabras con BERT sube el acierto de 70% a 77%

Ocho enfoques comparados sobre 340 titulares etiquetados a mano, con validación cruzada de 5 pliegues.



77%

de acierto (antes 70%), medido con notas que el modelo no vio

84%

de las notas negativas detectadas (antes 65%)

MÁS ALLÁ DEL DICCIONARIO

El sistema aprende lo que no le enseñamos

Tres técnicas para no depender solo de listas fijas.

FIGURAS NUEVAS (NER)

Fundación Faro
Gonzalo Belloso

spaCy detecta personas e instituciones que no están en el diccionario y marca las que irrumpen hoy en la agenda.

BÚSQUEDA POR SIGNIFICADO

0,85

Embeddings MiniLM: notas parecidas de otros medios aunque no compartan palabras. «Murió una joven embarazada…» y su par en La Voz: similitud 0,85.

APRENDIZAJE ACTIVO

76% → 76%

El modelo eligió los 60 titulares donde más dudaba; los etiquetamos a mano y reentrenamos. Eran casos ambiguos: la frontera del criterio.

EL DÍA EN UN NÚMERO

Un termómetro y un resumen que se escriben solos

Porcentaje estimado de notas negativas de las últimas 24 horas, de 0 a 100, contra los días anteriores.

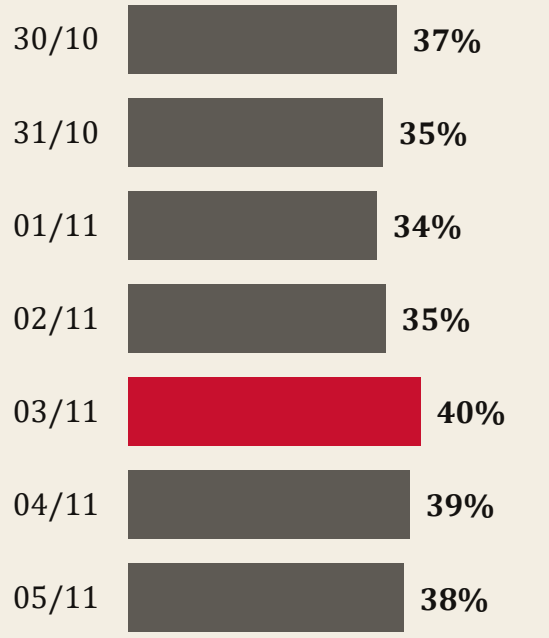


↓ 1 pt vs. el promedio de 7 días (36,8%)

RESUMEN DEL DÍA

ROSARIO — En las últimas 24 horas se publicaron 6.153 notas; el 36% tuvo tono negativo (moderado). La historia más compartida de los últimos días llegó a 22 medios; la publicó primero Canal 26. La figura más mencionada es Javier Milei. El medio más negativo de la base es Diario Chaco (51%) y el menos, El Chubut (18%).

% NEGATIVO, 7 DÍAS



CÓMO TITULA CADA MEDIO

Tres indicadores para medir el estilo, no solo el contenido

Cada uno con un ejemplo real de los últimos días.

1 Exageración

El título es negativo y la bajada del propio medio no lo es.

EL TRIBUNO · 15:13

Condenaron a un docente en Tartagal por abusar sexualmente de un alumno

TÍTULO: NEGATIVO

BAJADA DEL MEDIO · NEUTRA

El hecho ocurrió en 2021, cuando el hombre, que tiene 63 años, se desempeñaba como profesor de primer año del secundario.

2 Cebo

Preguntas, exclamaciones, adjetivos exagerados, intriga, segunda persona, listas.

INFOBAE · 13:45

Lo que debes saber sobre las amenazas de bomba contra vuelos en Europa

RECURSOS: ADJETIVO EXAGERADO · INTRIGA · SEGUNDA PERSONA

3 Transparencia

Notas firmadas por una persona; «Redacción» o el nombre del medio no cuentan.

INFOBAE · 15:45

Honduras aprueba 14 de 22 indicadores de la Cuenta del Milenio

POR PAMELA BUSTILLO

PERFIL · 15:56

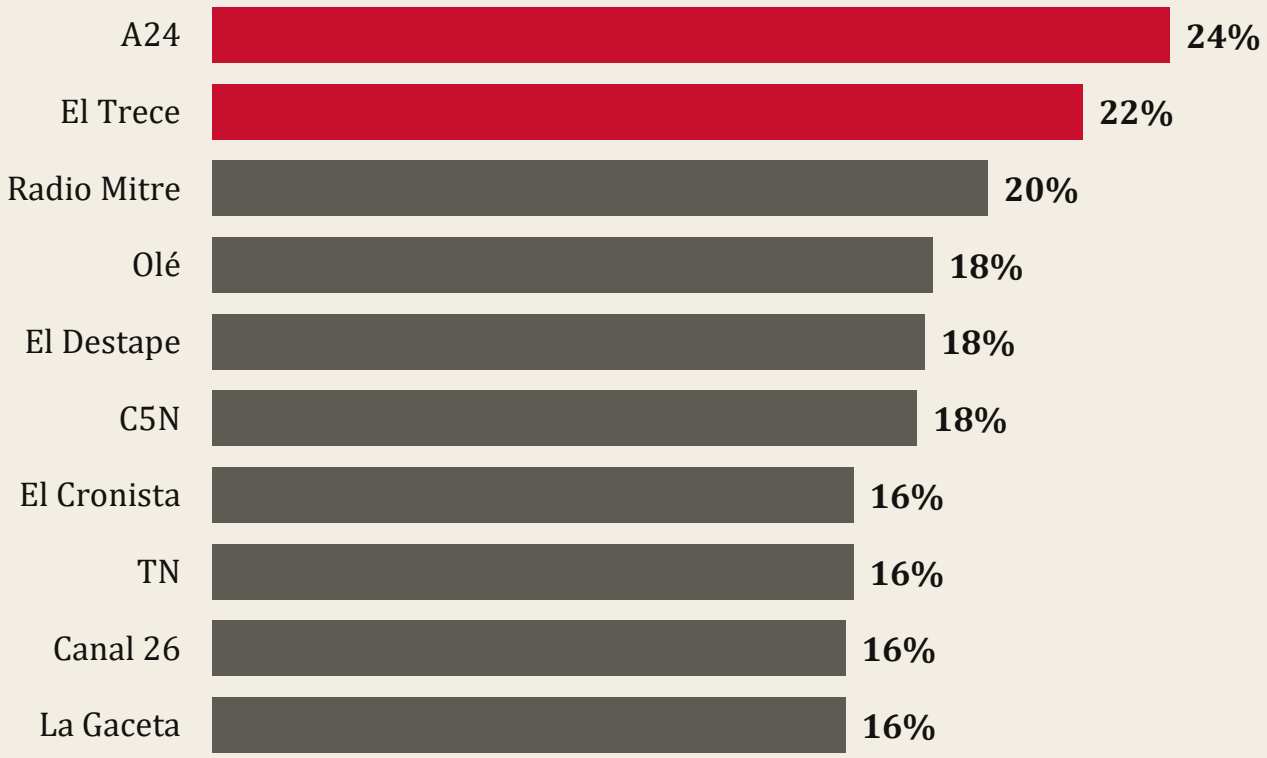
Isabel Macedo reinventó el clásico blazer con un giro fashionista

POR REDACCIÓN CARAS · NO CUENTA

CEBO

A24 y El Trece usan cebo en más de 1 de cada 4 títulos

En el otro extremo, Diario Chaco, Elonce y El Chubut no llegan al 4%.



MARCADOS POR EL SISTEMA

A24 · 14:26
¿Se terminó? El insólito motivo por el que Karina Jelinek dejó de ser "casi vegana"

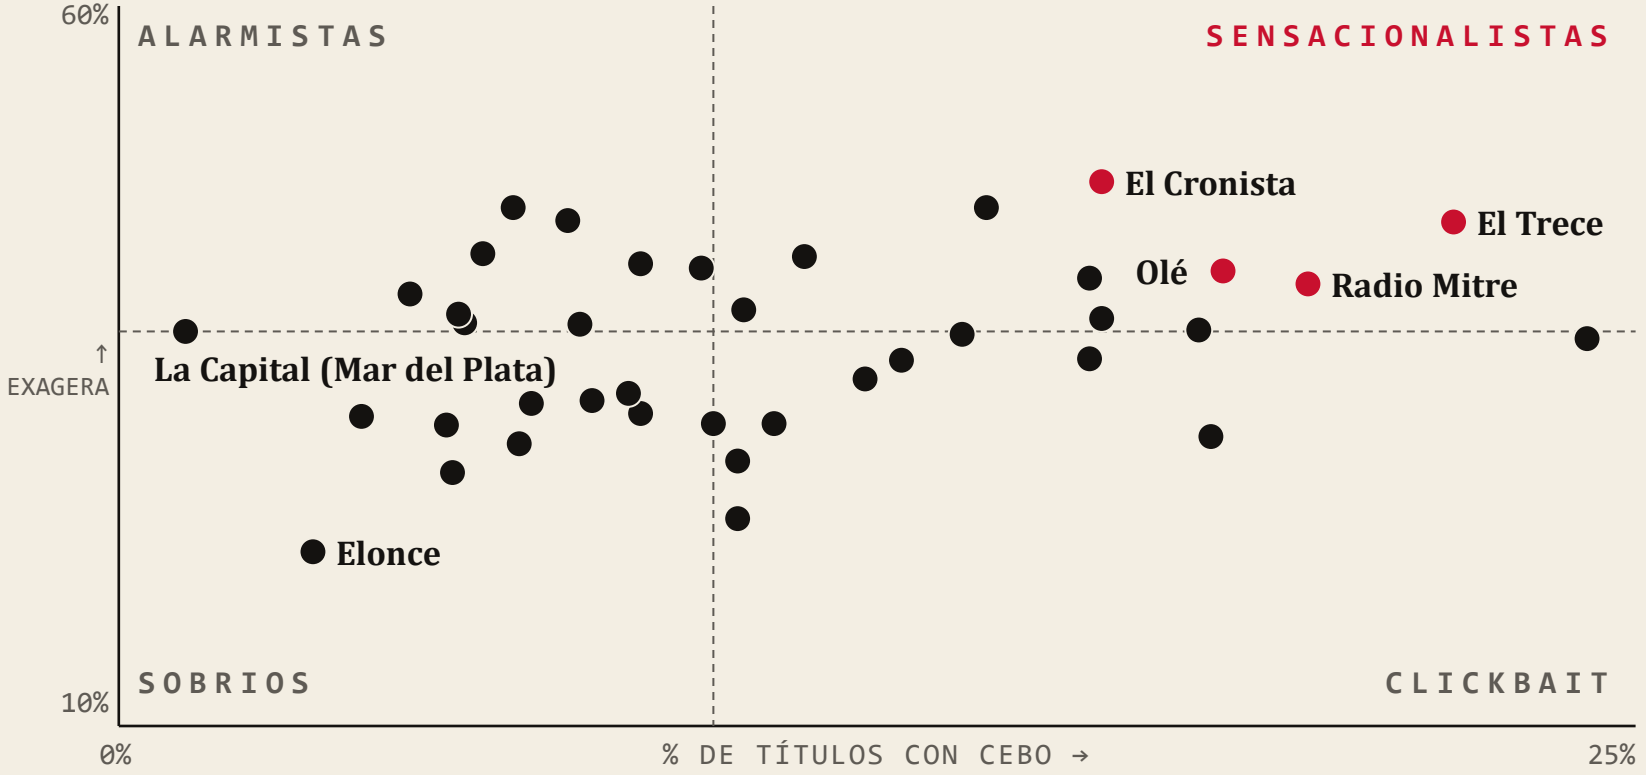
CADENA 3 · 10:12
"No somos cadetes de nadie": el cartel por las compras del Cyber Monday que se volvió viral

RÍO NEGRO · 09:22
Inés Estévez y Germán Palacios en «El hombre inesperado»: todo lo que queremos es ser felices

SENSACIONALISMO

El mapa: quién exagera y quién busca el clic

Cada punto es un medio. A la derecha, más cebo; arriba, más exageración respecto de su propia bajada.



CÓMO LEERLO

Arriba a la derecha: títulos con cebo que además exageran el hecho.

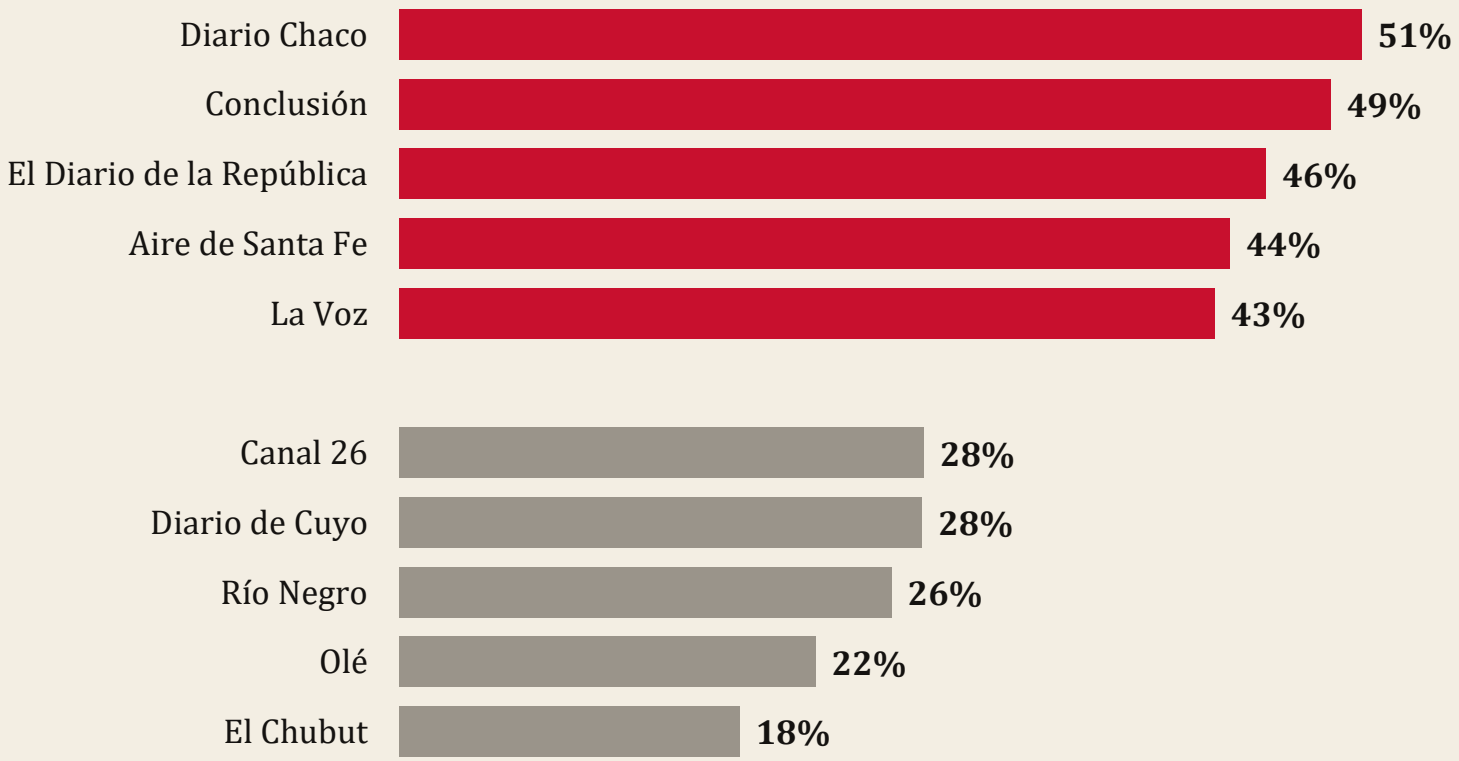
Abajo a la izquierda: títulos sobrios y fieles a su bajada.

Las líneas punteadas son las medianas de los medios.

TONO

Diario Chaco: 51% de notas negativas. El Chubut: 18%

Los cinco medios más negativos y los cinco menos negativos de la base.



EN TODA LA BASE · 84.040 NOTAS

37% negativas

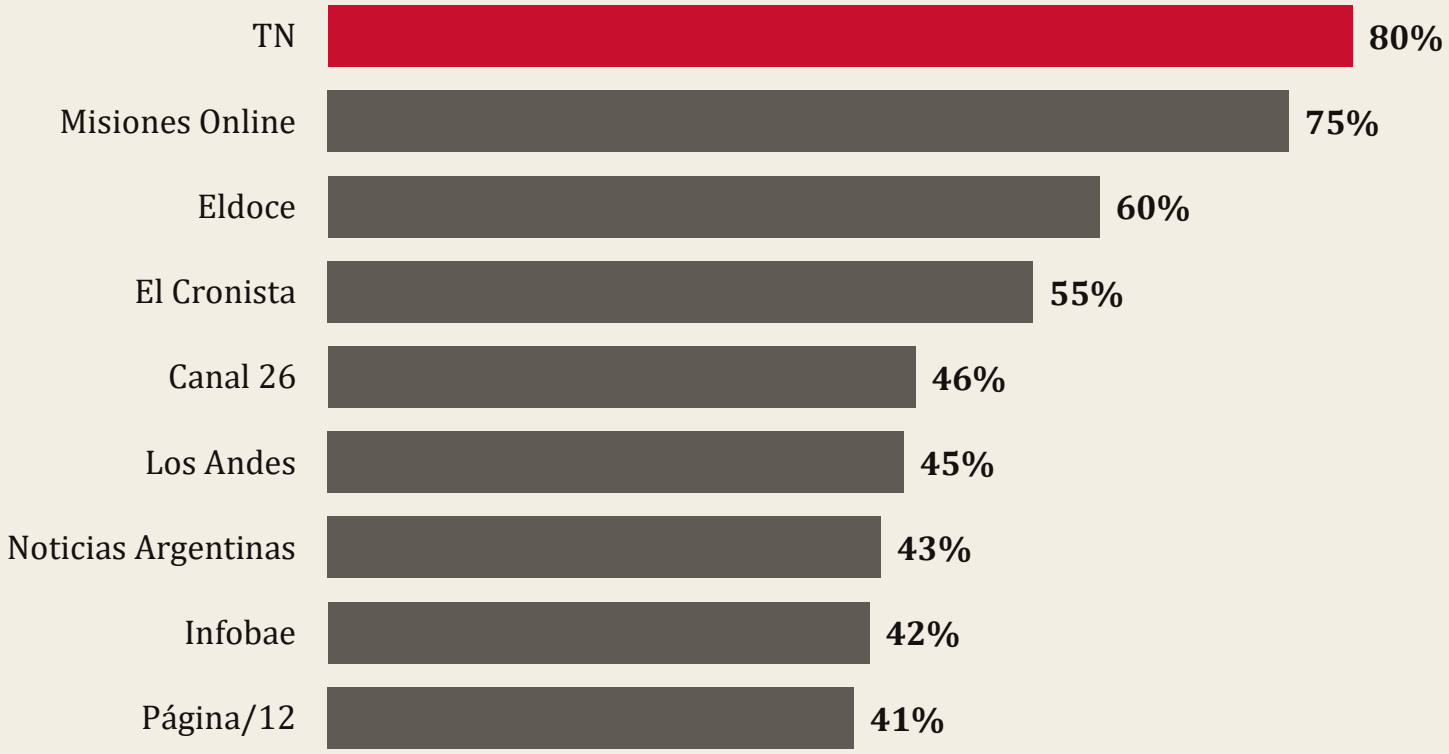
50% neutras

13% positivas

TRANSPARENCIA

TN firma el 80% de sus notas; 5 medios, ninguna

Notas firmadas por una persona, según el autor que declara el JSON-LD de cada nota.



SIN NINGUNA NOTA FIRMADA

Conclusión
Elonce
La Capital (Mar del Plata)
Radio Continental
Rosario Nuestro

0% de notas con firma de una persona

ENCUADRE

Una noticia, muchos encuadres

Una misma historia en 10 medios, en orden de publicación, con el tono que el sistema le asigna a cada título.

DIARIO CHACO · 11:41 · PRIMERO

"Beautiful morning", el mensaje socarrón de Cristina Kirchner tras la derrota de Trump

TONO: POSITIVO

CONCLUSIÓN · 11:48 · +6 min

"Beautiful morning": el mensaje de Cristina después de haber anticipado la derrota de Trump

TONO: POSITIVO

NOTICIAS ARGENTINAS · 14:22 · +2 h 41

La respuesta de Bullrich a Cristina por las elecciones en EE. UU.: "Freedom is beautiful"

TONO: POSITIVO

INFOBAE · 14:34 · +2 h 53

"Beautiful morning", el mensaje de Cristina Kirchner sobre la derrota de Donald Trump

TONO: POSITIVO

CADENA 3 · 15:20 · +3 h 39

Bullrich le respondió a Cristina por las elecciones en Estados Unidos: "Freedom is beautiful"

TONO: POSITIVO

EL DESTAPE · 15:47 · +4 h 06

Patricia Bullrich se burló de que Cristina Kirchner esté presa: "Freedom is beautiful"

TONO: NEGATIVO

QUIÉN LLEGA PRIMERO

Medio que más veces publicó primero una historia que después cubrieron otros tres o más:

Infobae y Noticias Argentinas

64 veces en los últimos tres días, sobre 489 historias compartidas.

Esta historia: 4 títulos negativos, 1 neutro y 6 positivos.

TONO POR FIGURA

Cómo trata cada medio a cada figura

Porcentaje de notas negativas cuando el medio menciona a la figura, contra el promedio de todos los medios.

	JAVIER MILEI	PAPA LEÓN XIV	DONALD TRUMP	BOCA	RIVER	LIONEL MESSI
Infobae	40%	15%	53%	16%	23%	**3%**
Clarín	41%	12%	56%	**33%**	23%	14%
TN	34%	14%	50%	10%	25%	17%
La Nación	52%	14%	56%	11%	11%	7%
Perfil	42%	15%	63%	**28%**	23%	15%
Cadena 3	39%	9%	**39%**	12%	15%	14%
Río Negro	**27%**	15%	44%	16%	14%	6%
Todos los medios	41%	13%	54%	15%	20%	15%

CÓMO LEERLA

Rojo: más negativo que el promedio de los medios con esa figura.

Verde: menos negativo.

Celdas con 10 notas o más; «·», sin datos suficientes.

MINERÍA DE ESTRUCTURA

El mapa de medios: quién comparte agenda con quién

Dos medios quedan unidos cuando cubren las mismas historias; los colores son comunidades detectadas solas.

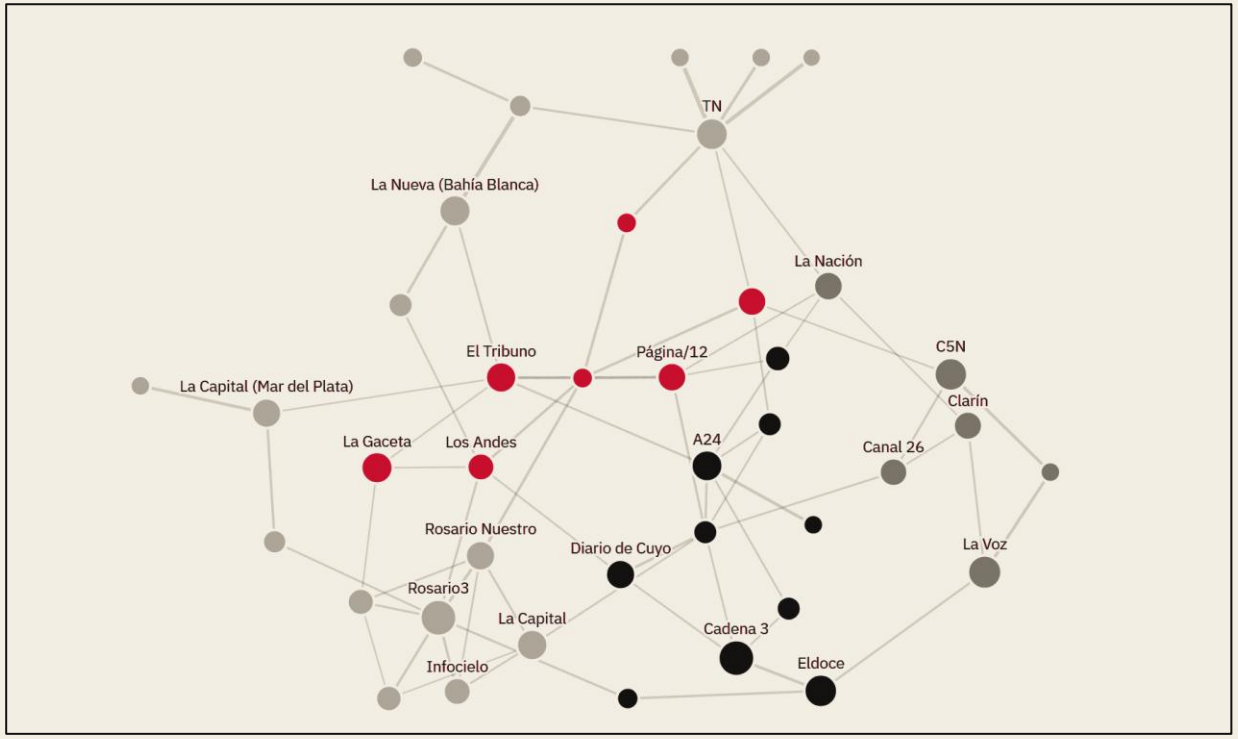


FOTO: TABLERO, PESTAÑA ANÁLISIS · COLORES = COMUNIDADES

CÓMO SE ARMA

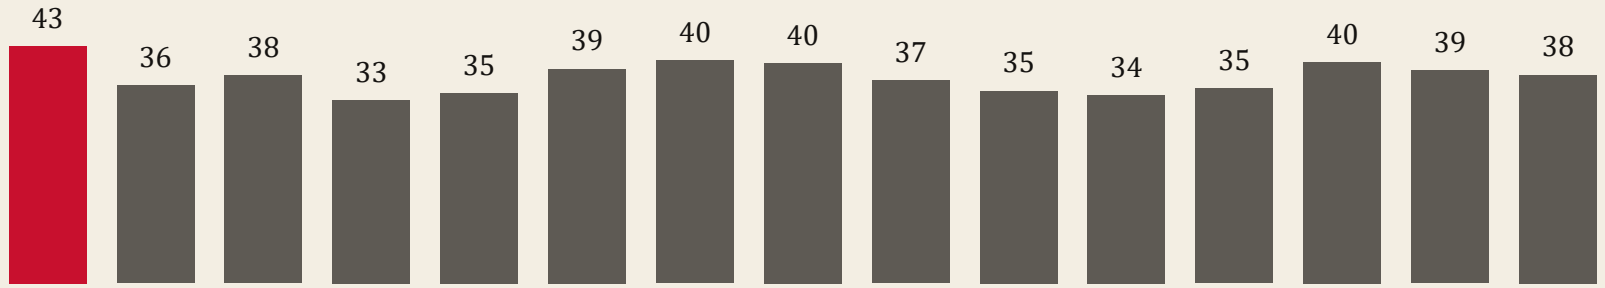
- Nodos: medios; el tamaño, según historias compartidas
- Aristas: los dos cubren las mismas historias
- Colores: comunidades por propagación de etiquetas
- Disposición por fuerzas, animada en el tablero

CLIMA MEDIÁTICO Y DÓLAR

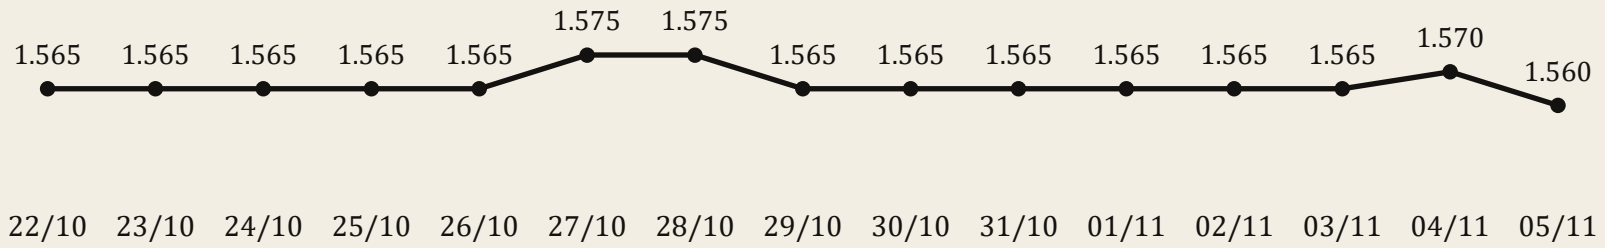
¿Se pone más negativa la agenda cuando sube el dólar?

% de notas negativas y dólar blue, día por día (15 días). Dos gráficos alineados, un solo calendario.

% DE NOTAS NEGATIVAS POR DÍA



DÓLAR BLUE, VENTA ($)



LO QUE SE PUEDE DECIR

r = 0,31

con 15 días: no se distingue del azar. Y el blue casi no se movió: entre $1.540 y $1.575 en 30 días.

No afirmamos correlación. La serie se sigue acumulando: con meses de datos se podrá probar.

EL TABLERO · DEMO EN VIVO

Todo esto, en un tablero público que se consulta con SQL

Una página estática en GitHub Pages: funciona en el celular y abre la base en el navegador, sin instalar nada.



FOTO: EL TABLERO, PESTAÑA RESUMEN

```
SELECT medio,
  ROUND(100*AVG(cebo>=1), 1) AS cebo,
  ROUND(100*AVG(tono='n'), 1) AS neg
FROM notas
GROUP BY medio
HAVING COUNT(*) >= 50
ORDER BY cebo DESC;
```

RESULTADO

medio	cebo	neg
A24	26,6	43,0
El Trece	23,0	40,3
C5N	21,5	41,0
Radio Mitre	20,2	34,3
El Destape	20,2	43,0

FICHA TÉCNICA

Staff: un stack simple, gratuito y reproducible

Sin servidores ni costos: todo corre en GitHub. Así se reparten las tareas en la redacción.

STAFF

CRONISTAS · RECOLECCIÓN

requests · feedparser · googlenewsdecoder · urllib.robotparser

CORRECTORES · EXTRACCIÓN

expresiones regulares · JSON-LD (schema.org) · HTML

EDITORES · LENGUAJE

bolsa de palabras · Naive Bayes · regresión logística · XLM-RoBERTa · MiniLM · spaCy

ARCHIVO · DATOS

SQLite · CSV · Datasette Lite · notebook con pandas

IMPRENTA · AUTOMATIZACIÓN

GitHub Actions cada 30 minutos · pruebas automáticas

DIAGRAMACIÓN · VISUALIZACIÓN

HTML, CSS y JavaScript sin frameworks · GitHub Pages

EDITORIAL

Cómo nos cuentan las noticias: lo que aprendimos

Tres conclusiones, con la cautela de una medición automática con error conocido.

I

El estilo se mide

El cebo y la exageración separan a los medios de forma estable: A24 y El Trece titulan con cebo en más de 1 de cada 4 notas; El Chubut, casi nunca.

II

El tono mide el hecho

No la postura del medio. Palabras + BERT llegan a 77%; lo que falla son titulares ambiguos, la frontera del propio criterio.

III

La agenda es compartida

En tres días, 489 historias llegaron a tres medios o más. Se puede medir quién llega primero y cómo encuadra cada uno.

> *Cada día los medios cuentan los mismos hechos con énfasis distintos. Ahora lo podemos medir.*

PROBALO AHORA

Gracias

Escaneá el código para abrir el tablero y consultar la base con SQL. ¿Preguntas?

Grupo 3: Martín Ceriotti · Miguel Garrone · Lucía Tamplin · Milagros Terán

Docentes: Enrique Fernández · Héctor E. Giorgiutti

CÓDIGO github.com/miguegarrone-blip/Web-Mining

UNIVERSIDAD AUSTRAL · SEDE ROSARIO · MAESTRÍA EN CIENCIA DE DATOS · 2026

EL TABLERO, EN VIVO

miguegarrone-blip.github.io/Web-Mining

Se actualiza cada 30 minutos. Funciona en el celular.