UNIVERSIDAD AUSTRAL · SEDE ROSARIO · WEB MINING

# ¿Cómo nos cuentan las noticias?

Un monitor automático de 46 medios argentinos: agenda, tono y estilo de titulación

**Grupo 3:** Martín Ceriotti · Miguel Garrone · Lucía Tamplin · Milagros Terán

Docentes: Enrique Fernández · Héctor E. Giorgiutti · Maestría en Ciencia de Datos · 2026

EL PROBLEMA

# Un mismo día, contado de 46 maneras distintas

- ¿De qué se habla hoy y qué crece respecto de lo habitual?
- ¿Qué medios cubren un tema o una persona, y con qué tono?
- ¿Qué noticias cubre todo el ecosistema y cuáles son exclusivas?
- ¿Quién titula de forma más alarmista o con más clickbait?
- ¿Cuánto contenido está firmado y cuánto sale como "Redacción"?

**≈3.000**

titulares por corrida, de 46 medios, cada media hora

Leerlos a mano es inviable: hay que extraerlos, estructurarlos y medirlos de forma automática.

LA SOLUCIÓN

# Un monitor que corre solo, cada 30 minutos, y publica todo

**46**

medios: diarios, portales, TV, radios y fuentes oficiales

**5.302**

notas en la base, con tema, tono, entidades y estilo de título

**24/7**

GitHub Actions cada 30 minutos; tablero y base SQL publicados en GitHub Pages

**Web mining de punta a punta:** crawling de feeds, scraping de cada nota, procesamiento de lenguaje con BERT, base de datos histórica e indicadores comparables entre medios.

ARQUITECTURA

# Seis etapas, de los feeds al tablero

**1**

**Feeds**

RSS y Google News de 46 medios, en paralelo

→

**2**

**Validación**

Descarta no-notas, fechas imposibles y duplicados

→

**3**

**Scraping**

Entra a cada nota: bajada y JSON-LD

→

**4**

**Lenguaje**

Tema, entidades, tono con BERT, cebo

→

**5**

**SQLite**

Histórico de 21 días, CSV exportable

→

**6**

**Tablero**

8 pestañas + SQL en el navegador

**Automatización:** GitHub Actions corre el pipeline cada 30 minutos, guarda la base en una rama de datos y publica el tablero en GitHub Pages. La primera corrida con BERT tarda 10 minutos; las siguientes, 2.

FUENTES

# Dos vías para llegar a 46 medios sin claves ni costo

## RSS propio — 17 medios

- Feed XML del medio: título, enlace, fecha y bajada
- La vía más limpia y estable
- Clarín, Infobae, La Nación, La Capital, TN…

## Google News por sitio — 29 medios

- Búsqueda site:dominio de las últimas 48 h
- Cubre los medios sin RSS útil
- Pero devuelve una URL de Google y sin bajada

**3.724 de 5.302 notas** llegaron por Google News: sin el paso siguiente, solo tendríamos su título.

SCRAPING

# Entramos a cada nota para leer lo que el RSS no trae

**100%**

de las notas analizadas entrando a su página

**87%**

con bajada (el resumen del propio medio)

### Del HTML de cada nota extraemos

- **URL real:** decodificando el enlace de Google News
- **Bajada:** meta og:description o primer párrafo real
- **Autor y firma:** persona o "Redacción", desde el JSON-LD
- **Sección y palabras clave:** como las clasifica el propio medio
- **Largo del cuerpo:** cantidad de palabras de la nota

ÉTICA DESDE EL DISEÑO

# Un crawler "bien educado", como pide la teoría

### robots.txt

Se lee por dominio antes de pedir una nota. 0 bloqueos en 5.548 pedidos.

### Nos identificamos

User-Agent propio que enlaza al proyecto: monitor-de-medios/1.0

### Carga acotada

Máximo 2 pedidos a la vez por sitio y topes de notas y tiempo por corrida.

### Sin insistir

Reintentos con espera creciente; una nota que falla dos veces no se vuelve a pedir.

*No guardamos el texto completo de las notas: solo título, bajada y metadatos, siempre con enlace al original.*

# La web cambia: el scraper se vigila a sí mismo

| Síntoma | Causa | Solución |
|---|---|---|
| Bajadas con código JavaScript | El respaldo de "primer párrafo" tomaba <path o código de un carrusel | Solo <p> reales, sin scripts; se descarta texto con forma de código |
| """ en el texto | Sitios que escapan las entidades dos veces | Doble decodificación de entidades HTML |
| "podrÃ¡" en vez de "podrá" | Páginas UTF-8 sin charset leídas como Latin-1 | Forzar UTF-8 y reparar los tramos rotos |
| Medio caído o degradado | Feed vacío o con menos de la mitad de lo habitual | Tabla salud y alerta en el tablero |

PROCESAMIENTO DE TEXTO

# Cada nota recibe tema, entidades, tono y cebo



## Temas

15 temas. Reglas sobre título + bajada, y un Naive Bayes que aprende de lo que las reglas ya clasificaron (supervisión débil).

**"Otros": 24% → menos del 5%**



## Entidades

35 personas, instituciones y clubes con sus alias y reglas de desambiguación ("Banco Central" no es Rosario Central).

**Más mencionados: Milei, Messi, el papa**

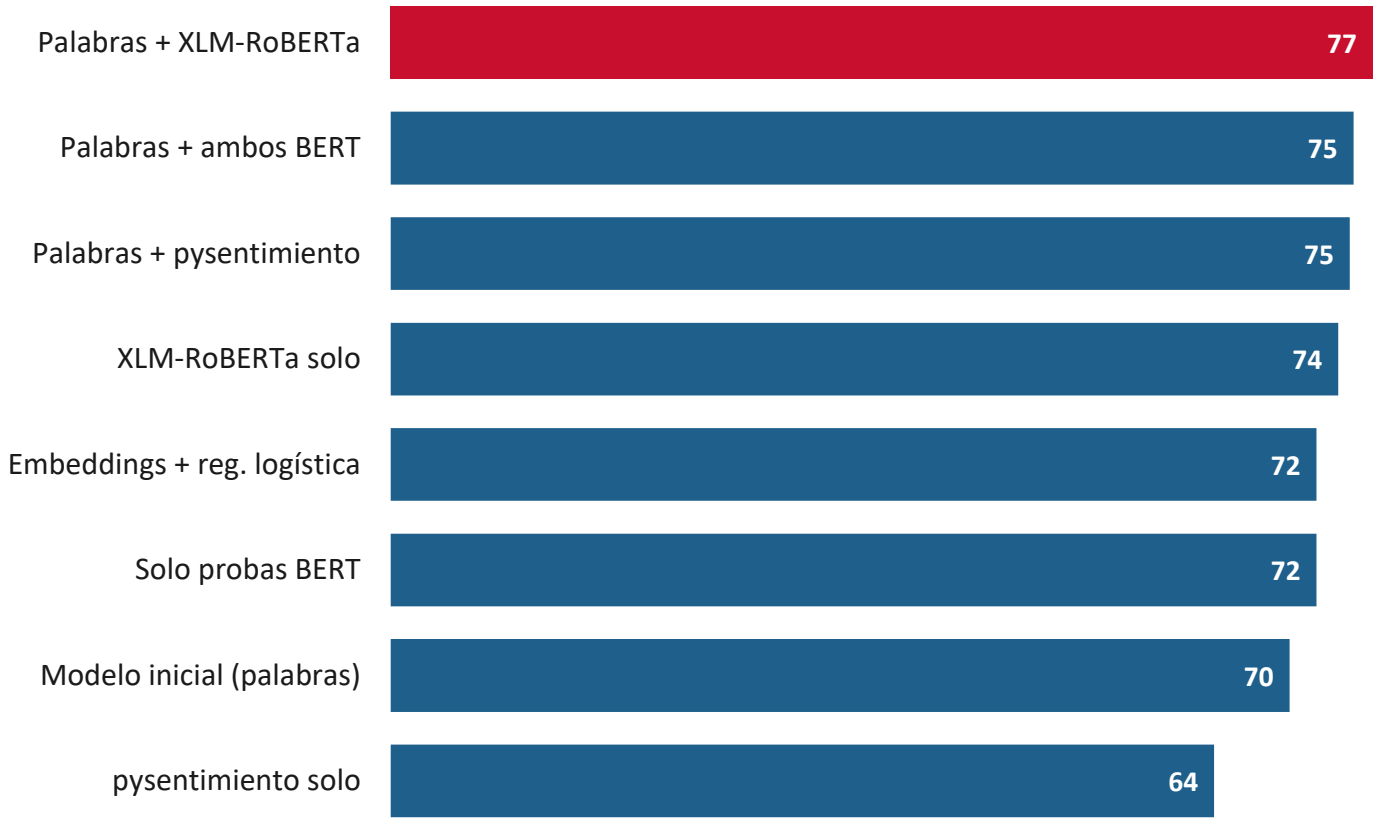


## Tono

Si el hecho es bueno o malo para los involucrados. Palabras + probabilidades de BERT, sobre el título y sobre la bajada.

**77% de acierto con validación cruzada**

# Combinar palabras con BERT sube el acierto de 70% a 77%




**77%**

de acierto (antes 70%), medido con notas que el modelo no vio

**84%**

de las notas negativas detectadas (antes 65%)

MÁS ALLÁ DEL DICCIONARIO

# El sistema aprende lo que no le enseñamos



## Figuras nuevas (NER)

spaCy detecta personas e instituciones que no están en el diccionario y marca las que irrumpen hoy en la agenda.

**Ej.: Fundación Faro, Gonzalo Belloso**



## Búsqueda por significado

Embeddings MiniLM: notas parecidas de otros medios aunque no compartan palabras, y búsqueda semántica en el navegador.

**"Murió una joven embarazada…" ↔ La Voz: 0,85**



## Aprendizaje activo

El modelo de tono eligió los 60 titulares donde más dudaba; los etiquetamos a mano y reentrenamos.

**Resultado: 76% → 76%; eran casos ambiguos**

EL DÍA EN UN NÚMERO

# Un termómetro y un resumen que se escriben solos




RESUMEN DEL DÍA

En las últimas 24 horas, **45 medios** publicaron **1.684 notas**. El tema más cubierto fue **Política** (21% de las notas), seguido por Seguridad y justicia. La noticia que más medios cubrieron fue «**La Justicia sobreseyó a Javier y Karina Milei en la causa $Libra**» (12 medios; la publicó primero El Cronista). La figura más mencionada fue **Javier Milei** (97 notas, ≈46% con tono negativo). El medio más negativo fue **Aire de Santa Fe** (≈48%) y el menos negativo, **Olé** (≈21%). El que más veces llegó primero a una historia compartida fue **Eldoce** (19 veces). El termómetro de negatividad marca **37 (moderado)**.

**Termómetro:** % de notas negativas de las últimas 24 h (calmo, moderado, tenso, muy tenso).

**Resumen:** redactado con plantillas a partir de los datos del día; sin modelo de lenguaje, reproducible.

# Tres indicadores para medir el estilo, no solo el contenido

**1**

## Exageración

El título es negativo y la bajada del propio medio no lo es.

*"El dramático relato…" → bajada: datos del vuelo y los pasajeros*

**2**

## Cebo (clickbait)

Preguntas, exclamaciones, adjetivos exagerados, intriga, segunda persona, listas.

*"¡Escándalo! Aseguran que…" · "El truco viral para…"*

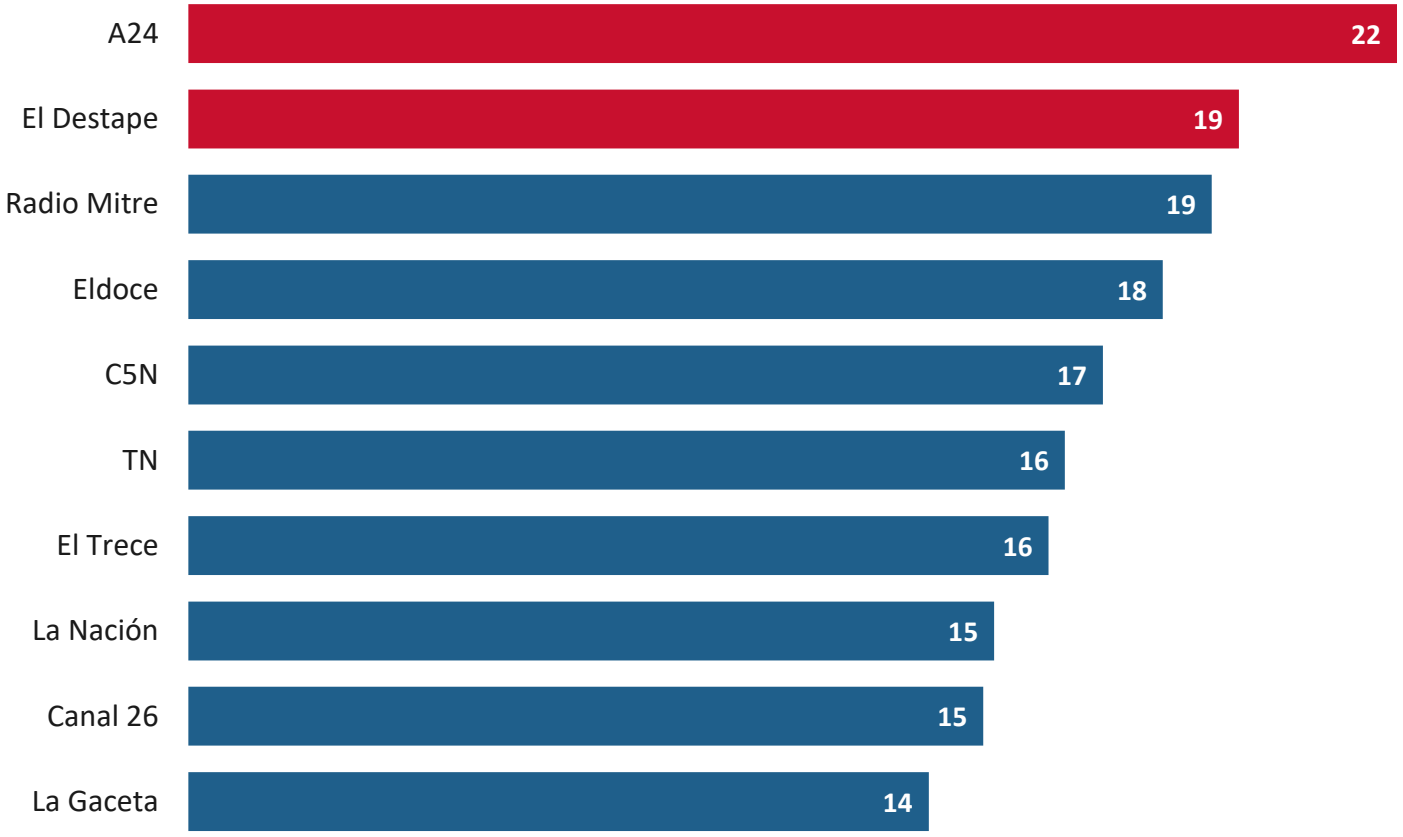
**3**

## Transparencia

Notas firmadas por un periodista, según los datos estructurados de la nota.

*"Redacción" o el nombre del medio no cuentan como firma*

# A24 y El Destape usan recursos de cebo en casi 1 de cada 5 títulos



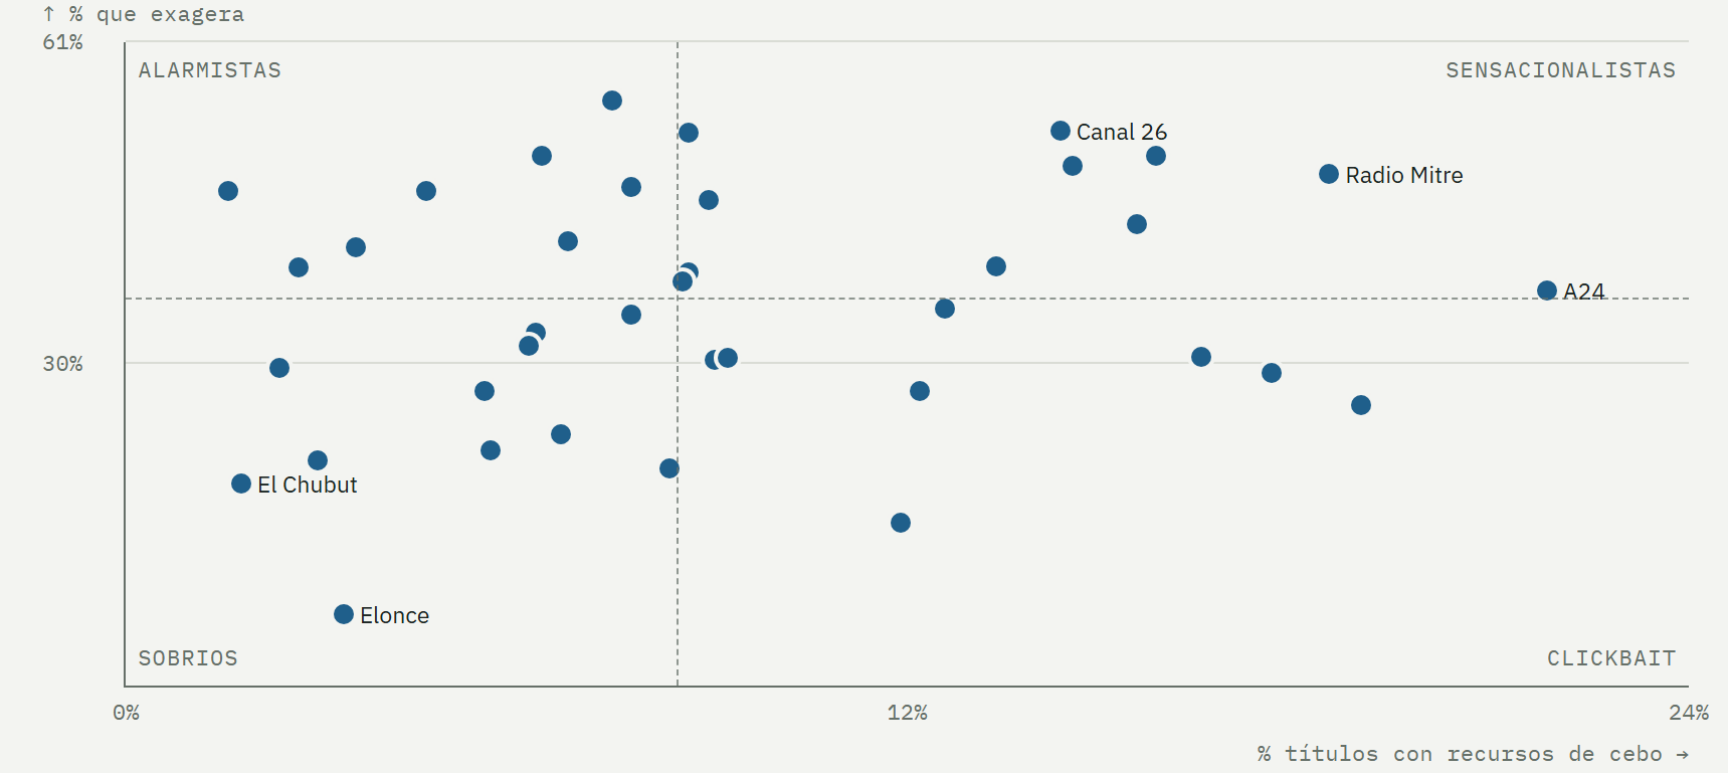

## En el otro extremo

- Perfil: 1,6%
- El Chubut: 1,8%
- Rosario Nuestro: 2,4%
- La Capital: 2,7%

Porcentaje de títulos con al menos un recurso de cebo; medios con 40 notas o más.

SENSACIONALISMO

# El mapa: quién exagera y quién busca el clic

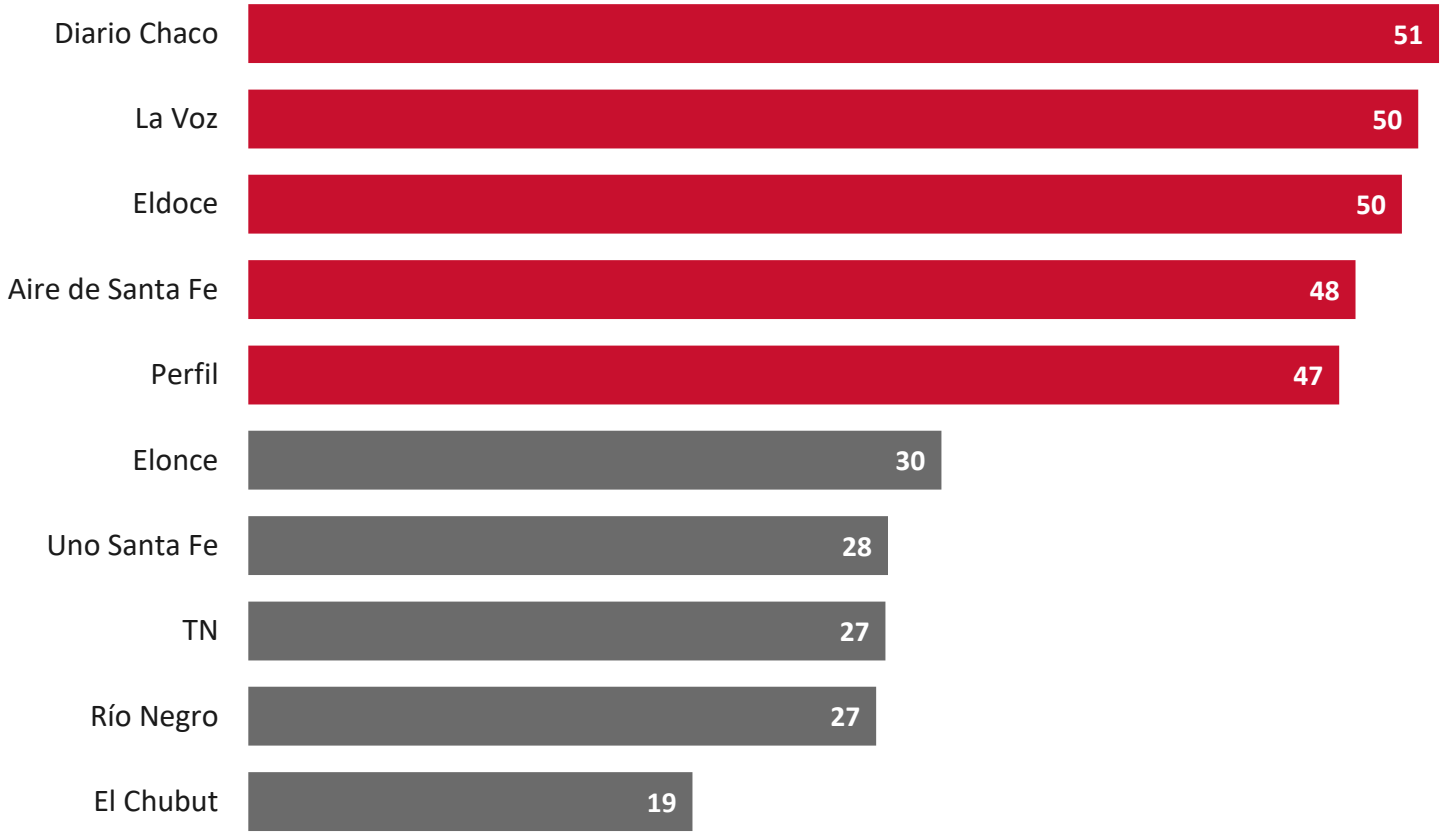



## Cómo leerlo

**Arriba a la derecha:** títulos con cebo que además exageran.

**Abajo a la izquierda:** títulos sobrios y fieles a su bajada.

# En Diario Chaco, 1 de cada 2 notas es negativa; en El Chubut, 1 de cada 5




**En toda la base**

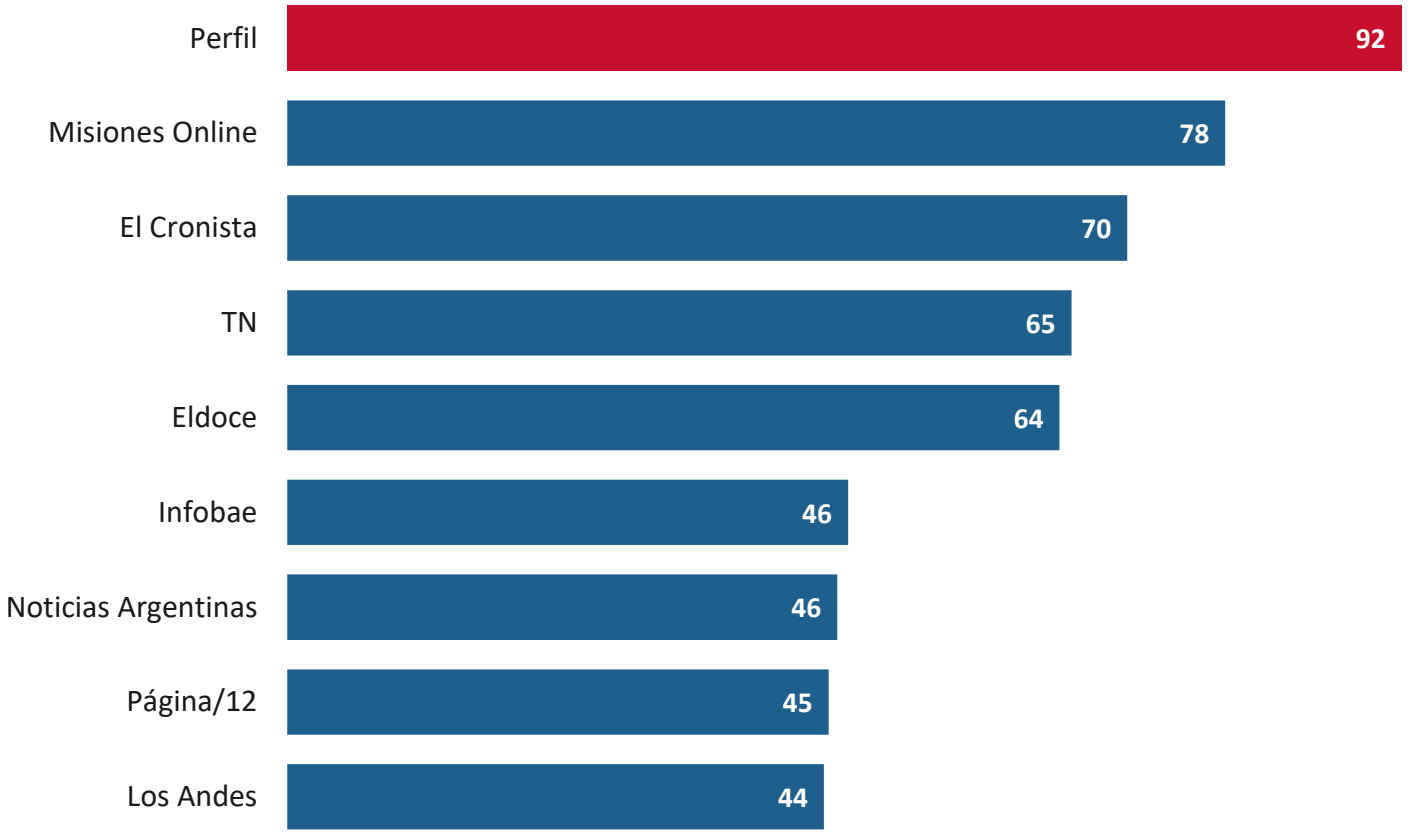
**39%** Negativo

**49%** Neutro

**13%** Positivo

TRANSPARENCIA

# Perfil firma el 92% de sus notas; Radio Mitre y Rosario3, ninguna




**Sin ninguna nota firmada**

- Elonce
- La Capital (Mar del Plata)
- Radio Continental
- Radio Mitre
- Rosario Nuestro
- Rosario3

ENCUADRE

# Una noticia, muchos encuadres




## Quién llega primero

Medio que más veces publicó primero una historia que después cubrieron otros:

**Eldoce**

Cada tarjeta muestra el tono del título, sus recursos de cebo y los minutos de demora respecto del primero.

TONO POR FIGURA

# Cómo trata cada medio a cada figura

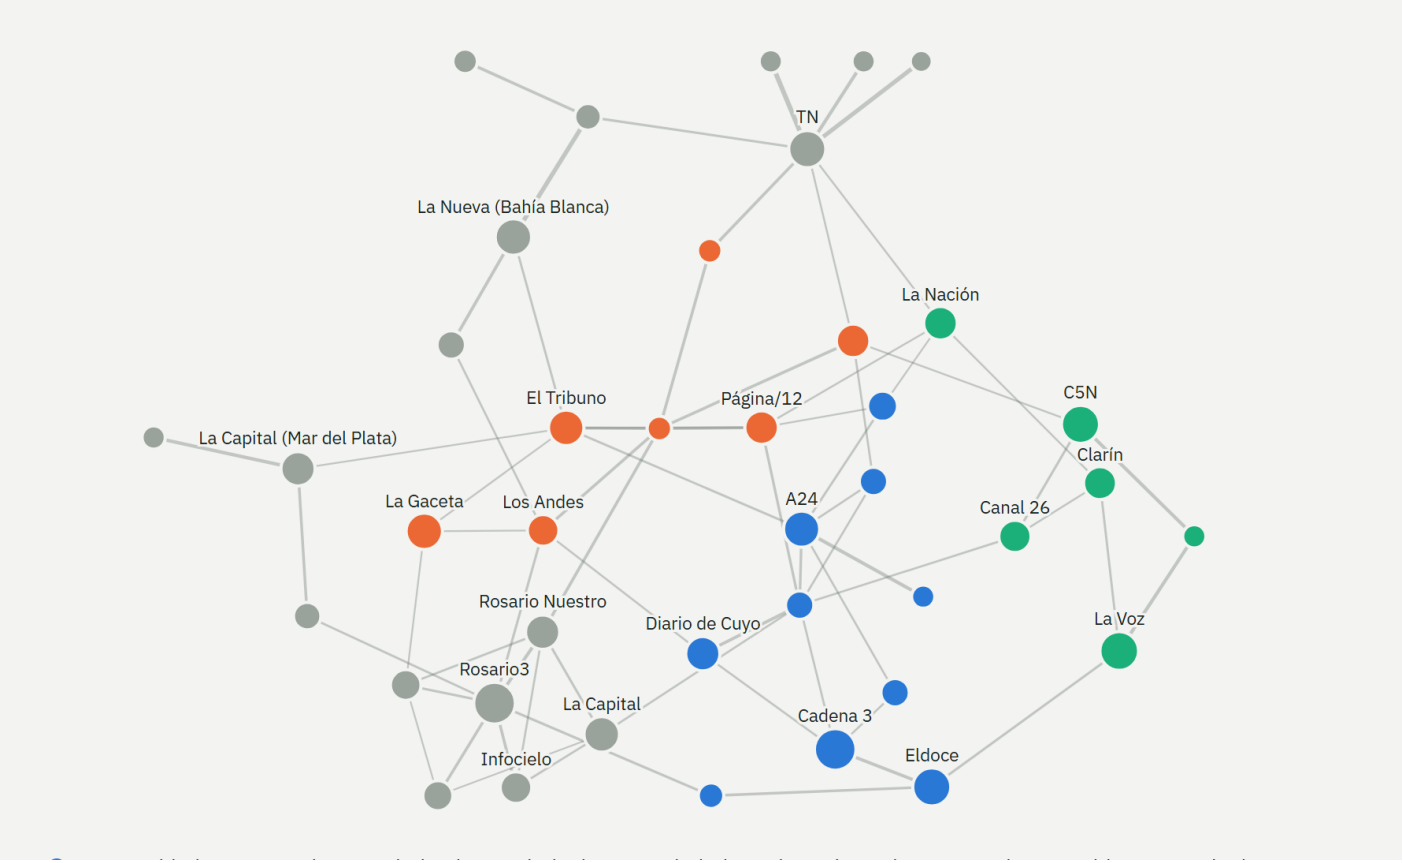
| | Javier Milei | Lionel Messi | Papa León XIV | Policía | Rosario Central | Donald Trump | Boca |
|---|---|---|---|---|---|---|---|
| Infobae | 73% (8) | · | · | 81% (14) | · | 26% (5) | · |
| Elonce | · | · | 33% (3) | · | · | · | · |
| TN | 47% (6) | · | · | · | · | · | 10% (3) |
| Clarín | 39% (10) | 8% (5) | · | · | · | 56% (14) | · |
| La Nación | 51% (7) | · | · | · | · | · | · |
| Radio Mitre | 26% (5) | 3% (4) | 18% (9) | 80% (3) | · | · | · |
| El Litoral | 7% (3) | 6% (5) | · | · | · | · | · |

**Rojo:** más negativo que el promedio de los medios con esa figura.

**Verde:** menos negativo.

Entre paréntesis, la cantidad de notas.

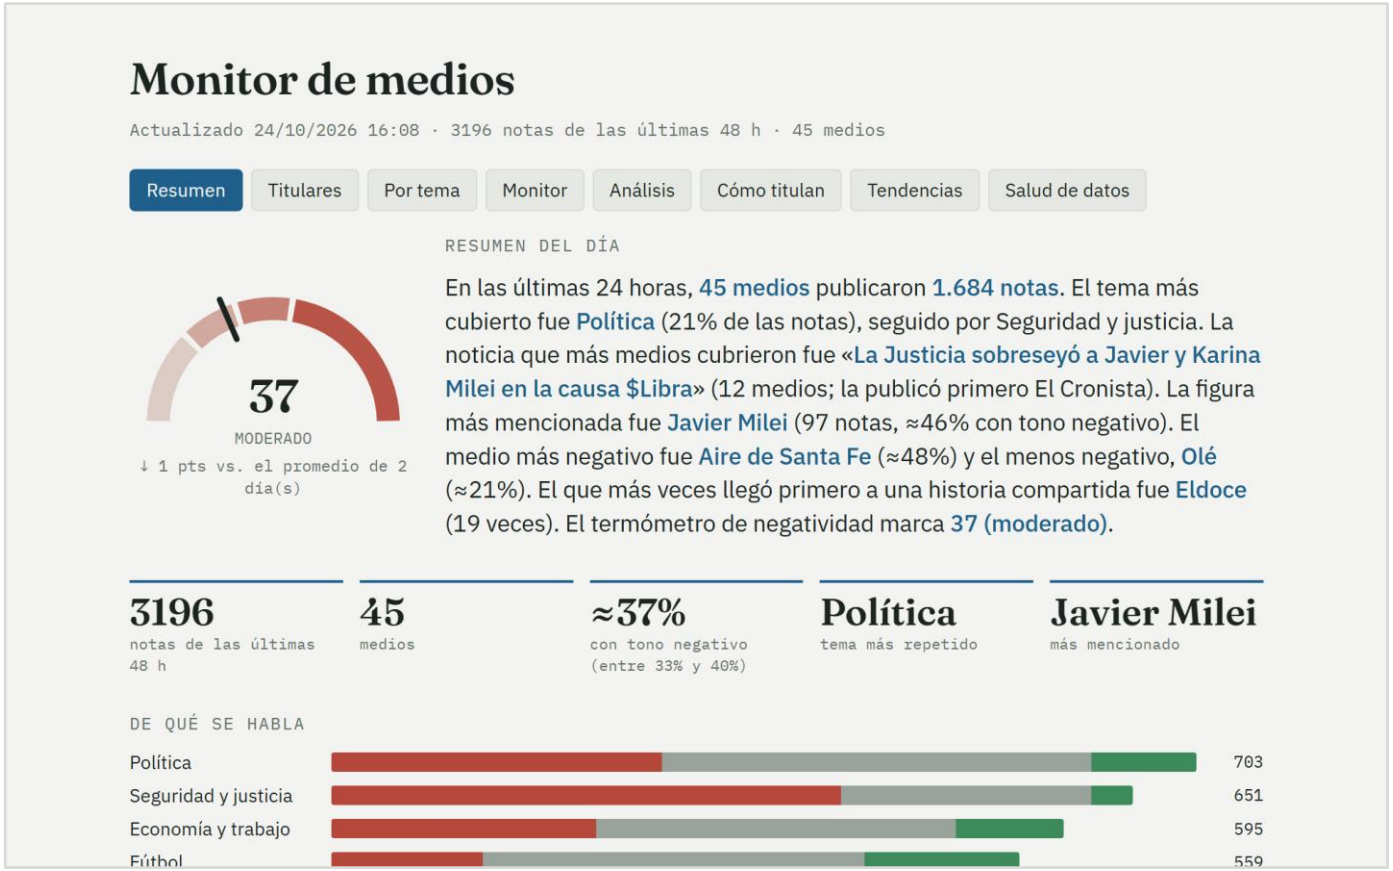
# El mapa de medios: quién comparte agenda con quién




## Cómo se arma

- Nodos: medios; tamaño según historias compartidas
- Aristas: cubren las mismas historias
- Colores: comunidades detectadas por propagación de etiquetas
- Disposición por fuerzas, animada en el tablero

# Todo esto, en un tablero público que se actualiza solo




**Resumen**
termómetro, resumen del día y noticias compartidas

**Titulares**
buscador por texto o por significado y notas parecidas

**Monitor**
figuras nuevas (NER) y seguimiento de una persona

**Análisis**
filtros, agenda, encuadre y mapa de medios

**Cómo titulan**
mapa, rankings y ejemplos

**Salud de datos**
fuentes y scraping

DEMO EN VIVO

# La base se consulta con SQL desde el navegador

```
SELECT medio,
  ROUND(100*AVG(cebo>=1), 1) AS cebo,
  ROUND(100*AVG(tono='n'), 1) AS neg
FROM notas
GROUP BY medio
HAVING COUNT(*) >= 50
ORDER BY cebo DESC;
```

1. Abrir el tablero (QR al final)
2. Tocar "Explorar la base (SQL)"
3. Elegir la tabla items o escribir una consulta
4. Descargar la base o el CSV si se quiere

HERRAMIENTAS

# Un stack simple, gratuito y reproducible

### Recolección

requests · feedparser · googlenewsdecoder · urllib.robotparser

### Extracción

expresiones regulares · JSON-LD (schema.org) · HTML

### Lenguaje

bolsa de palabras · Naive Bayes · regresión logística · XLM-RoBERTa · MiniLM · spaCy (NER)

### Datos

SQLite · CSV · Datasette Lite · notebook con pandas

### Automatización

GitHub Actions (cada 30 min, autodisparo) · pruebas automáticas

### Visualización

HTML, CSS y JavaScript sin frameworks · GitHub Pages

LO QUE SIGUE

# Limitaciones honestas y próximos pasos

## Limitaciones

- Tono del título y la bajada, no de la nota completa
- 77% de acierto con 340 etiquetas de un solo criterio
- Pocos días de histórico: los rankings se estabilizan con semanas
- Temas y entidades por diccionario requieren mantenimiento

## Próximos pasos

- Completar rondas de aprendizaje activo y medir la mejora
- Evolución de las comunidades a lo largo de las semanas
- Con más días: ¿el tono acompaña al dólar?
- Más etiquetas manuales, con varios anotadores

PROBALO AHORA

# Gracias

Escaneá el código para abrir el tablero y consultar la base con SQL

miguegarrone-blip.github.io/Web-Mining

Grupo 3 · Martín Ceriotti · Miguel Garrone · Lucía Tamplin · Milagros Terán

Código: github.com/miguegarrone-blip/Web-Mining