Año I · N.º 628 Edición especial · Web Mining · Grupo 3 Se actualiza cada 30 minutos

La Tapa

El diario que lee a los diarios

ROSARIO, VIERNES, 6 DE NOVIEMBRE DE 2026 DATOS: 06/11/2026 16:48

UNIVERSIDAD AUSTRAL · MAESTRÍA EN CIENCIA DE DATOS

¿Cómo nos cuentan las noticias?

Un monitor automático de 46 medios argentinos: agenda, tono y estilo de titulación.

Por Grupo 3: Martín Ceriotti · Miguel Garrone · Lucía Tamplin · Milagros Terán
Docentes: Enrique Fernández · Héctor E. Giorgiutti
Universidad Austral · Sede Rosario · 2026

PÁG. 4
Cómo funciona: de los feeds al tablero

PÁG. 11
Qué encontramos en 46 medios

PÁG. 21
La base, en vivo y con SQL

Hoy: 2.838 titulares de 46 medios

El Destape 06:11

TENSO Saludo entre JAVIER MILEI y PEDRO SÁNCHEZ en la Cumbre Iberoamericana

Perfil

¿Por qué los manifestantes indios tienen en el punto de mira a la Comisión Electoral?

Rosario3 16:19

Central: Campaz y Pizarro, otra vez citados a sus selecciones para la próxima fecha FIFA

EL PROBLEMA

Un mismo día, contado de 46 maneras

El Destape 06:11

TENSO Saludo entre JAVIER MILEI y PEDRO SÁNCHEZ en la Cumbre...

Diario de Cuyo 07:20

Javier Milei y Pedro Sánchez, un saludo frío y fugaz en la apertura del plenari...

C5N 07:30

Video: el frío saludo entre Javier Milei y Pedro Sánchez en la 30ª Cumbre...

La Voz 07:33

España. Frío saludo entre Milei y Sánchez en Madrid durante la Cumbre...

Diario Chaco 08:08

Milei y Pedro Sánchez tuvieron un frío saludo en la Cumbre Iberoamericana en...

Canal 26 08:10

Frío y rápido saludo entre Milei y Pedro Sánchez en la Cumbre Iberoamericana: el...

Recortes reales: la historia que más medios cubrieron en las últimas 48 h (**11 medios**), cada una con su hora de publicación. Agrupadas automáticamente por similitud de palabras.

SUMARIO: LO QUE QUEREMOS SABER

- ¿De qué se habla hoy y qué crece respecto de lo habitual?
- ¿Qué medios cubren un tema o una persona, y con qué tono?
- ¿Qué noticias cubre todo el ecosistema y cuáles son exclusivas?
- ¿Quién titula de forma más alarmista o con más cebo?
- ¿Cuánto contenido está firmado y cuánto sale como «Redacción»?

Datos actualizados: 06/11/2026 16:48

LA SOLUCIÓN

Un monitor que corre solo, cada 30 minutos, y publica todo

46

medios: diarios, portales, TV, radios y fuentes oficiales

84.302

notas en la base, con tema, tono, entidades y estilo de título

30'

entre corrida y corrida, en GitHub Actions, sin intervención

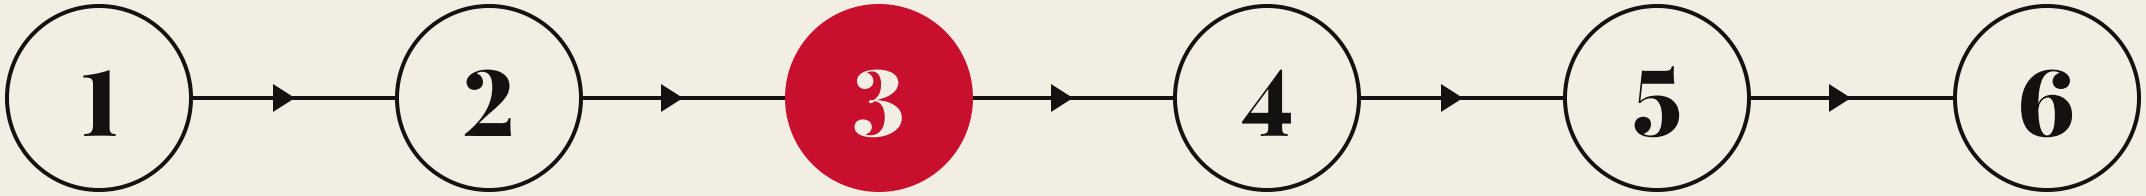
0 $

sin servidores ni claves: tablero, base SQL y código públicos

Web mining de punta a punta: crawling de feeds, scraping de cada nota, procesamiento de lenguaje con BERT, una base histórica de **16 días** e indicadores comparables entre medios. Esta edición sale de la corrida N.º 628 de las últimas tres semanas, del 06/11/2026 16:48.

CÓMO FUNCIONA

Seis etapas, de los feeds al tablero



1 Feeds

63 feeds

RSS y Google News de 46 medios, en paralelo

2 Validación

reglas + cuarentena

Descarta no-notas, fechas imposibles y duplicados

3 Scraping

100% de las notas

Entra a cada nota: bajada y datos JSON-LD

4 Lenguaje

4 modelos

Tema, entidades, tono con BERT y cebo

5 SQLite

84.302 notas

Histórico de 21 días y CSV exportable

6 Tablero

GitHub Pages

8 pestañas y SQL en el navegador

Automatización: GitHub Actions corre el pipeline cada 30 minutos, guarda la base en una rama de datos y publica el tablero y esta presentación en GitHub Pages. Por eso las cifras de estas páginas cambian solas.

FUENTES

Dos vías para llegar a 46 medios, sin claves ni costo

RSS propio · 17 medios **Google News por sitio · 29 medios**

RSS propio

El feed XML del medio: título, enlace, fecha y bajada. La vía más limpia y estable.

La Capital · Rosarioplus · El Ciudadano · Conclusión · Olé · Clarín · La Nación · Infobae · Perfil · Ámbito · Noticias Argentinas · TN · Aire de Santa Fe · El Día (La Plata) · Río Negro · Diario Chaco · Misiones Online

Google News por sitio

Búsqueda `site:dominio` de las últimas 48 h. Cubre los medios sin RSS útil, pero da una URL de Google y ninguna bajada.

Rosario3 · Página/12 · El Cronista · El Destape · Infocielo · C5N · A24 · El Trece · Canal 26 · Cadena 3 · Radio Mitre · Radio 10 · Radio Continental · El Litoral · La Voz · Eldoce · Los Andes · La Gaceta · El Tribuno · El Chubut · Rosario Nuestro · Uno Santa Fe · Elonce · La Nueva (Bahía Blanca) · La Capital (Mar del Plata) · El Diario de la República · Diario de Cuyo · Gobierno de Santa Fe · Municipalidad de Rosario

29.322 de 84.302 notas de la base llegaron por Google News: sin el paso siguiente, de esas solo tendríamos el título.

Datos actualizados: 06/11/2026 16:48

SCRAPING

Entramos a cada nota para leer lo que el RSS no trae

PÁGINA DE LISTADO

Cambio polémico en España: por qué el Barcelona y ...
16:37

Mundial de pádel: Argentina, finalista en ambas ra...
16:32

La primera lista de Portugal tras el retiro de Cri...
16:31

Por qué el gol de Beltrán cortó una espera inédita...
16:30

→

PÁGINA DE DETALLE

https://ole.com.ar/cambio-polemico-en-espana-por-… — URL real

FÚTBOL — Sección

Cambio polémico en España: por qué el Barcelona y el Atlético de Madrid se enfrentarán dos veces en menos de un mes

Los Blaugranas y los Colchoneros se verán las caras dos veces en 24 días debido. Acá las razones. — Bajada

Por **persona** o «Redacción» · 16:37 — Autor y firma

Fútbol | Internacional — Palabras clave

Largo del cuerpo

Los feeds son páginas de listado; cada nota es una página de detalle. Del HTML se lee la meta og:description y el bloque JSON-LD NewsArticle que los diarios incrustan para los buscadores.

100%
de las notas de la base, analizadas entrando a su página

82%
con bajada, en las notas leídas en las últimas 24 h

99%
con datos JSON-LD (autor, sección, palabras clave)

Datos actualizados: 06/11/2026 16:48

ÉTICA DESDE EL DISEÑO

Un crawler «bien educado», como pide la teoría

CÓDIGO DE CONDUCTA DEL MONITOR

Art. 1 robots.txt

Se lee por dominio antes de pedir una nota. **1 bloqueo** en 85.652 pedidos de las últimas tres semanas.

Art. 2 Nos identificamos

User-Agent propio que enlaza al proyecto: `monitor-de-medios/1.0`.

Art. 3 Carga acotada

Como máximo **2 pedidos a la vez por sitio**, con topes de notas y de tiempo por corrida.

Art. 4 Sin insistir

Reintentos con espera creciente; una nota que falla dos veces no se vuelve a pedir.

> ***No guardamos el texto completo de las notas: solo título, bajada y metadatos, siempre con enlace al original.***

PROCESAMIENTO DE TEXTO

Cada nota recibe tema, entidades, tono y cebo

Olé · 16:30 · nota real de las últimas horas

Por qué el gol de Beltrán cortó una espera inédita en River

TEMA

Fútbol · Clima y ambiente

Reglas sobre título y bajada, y un Naive Bayes que aprende de lo que las reglas ya clasificaron (supervisión débil).

ENTIDADES

River

Diccionario de 35 figuras con alias y desambiguación («Banco Central» no es Rosario Central), más spaCy.

TONO

negativo

Si el hecho es bueno o malo para los involucrados: palabras + probabilidades de XLM-RoBERTa.

CEBO

intriga

Preguntas, exclamaciones, adjetivos exagerados, intriga, segunda persona o listas. Marcados en rojo.

TONO CON BERT

Combinar palabras con BERT sube el acierto de 70% a 77%

ACIERTO DE 8 ENFOQUES (%)



340 titulares etiquetados a mano · validación cruzada de 5 pliegues · acierto sobre notas que el modelo no vio.

77%

de acierto con palabras + XLM-RoBERTa (antes, 70%)

84%

de las noticias negativas detectadas (antes, 65%)

MÁS ALLÁ DEL DICCIONARIO

El sistema aprende lo que no le enseñamos

Figuras nuevas (NER)

spaCy detecta personas e instituciones que no están en el diccionario.

Santiago Peña	72 notas · 30 medios
Franco Colapinto	37 notas · 23 medios
Ueno Bank	30 notas · 17 medios
Pampita	24 notas · 15 medios
UE	24 notas · 2 medios

Búsqueda por significado

Embeddings MiniLM: la misma noticia aunque no comparta palabras.

Conclusión

Lluvia, viento y leve caída de temperatura: ¿cómo estará el clima en Rosario durante el fin de semana?

La Capital

El tiempo en Rosario: viernes con posibles tormentas y ráfagas desde la tarde

similitud coseno entre los dos embeddings: 0,91

Aprendizaje activo

El modelo eligió los **60 titulares** donde más dudaba; los etiquetamos a mano y reentrenamos.

76% → 76%

acierto antes y después · en esos 60 casos el modelo coincidía solo en el 42%

> ***No eran errores aprendibles: eran titulares ambiguos. La ronda delimitó la frontera del criterio.***

EL DÍA EN UN NÚMERO

Un termómetro y un resumen que se escriben solos



35

MODERADO

% estimado de notas negativas, últimas 24 h, de 0 a 100 · línea punteada: promedio de 15 días (36)

ROSARIO, VIERNES, 6 DE NOVIEMBRE —

En las últimas 24 horas, **46 medios** publicaron **2.838 notas.** El tema más cubierto fue **Economía y trabajo** (22% de las notas), 0,6 veces su promedio diario, seguido por Política. La noticia que más medios cubrieron fue «**Milei en la Cumbre Iberoamericana: frío saludo a Pedro Sánchez, ataque al socialismo y reclamo por Malvinas**» (11 medios; la publicó primero El Destape). La figura más mencionada fue **Papa León XIV** (224 notas, ≈17% con tono negativo). El medio más negativo fue **El Destape** (≈47%) y el menos negativo, **El Chubut** (≈19%). El que más veces llegó primero a una historia compartida fue **Noticias Argentinas** (37 veces). El termómetro de negatividad marca **35 (moderado).**

Redactado con plantillas a partir de los datos, igual que en el tablero: sin modelo de lenguaje, reproducible.

CÓMO TITULA CADA MEDIO

Tres indicadores para medir el estilo, no solo el contenido

Exageración

El título es negativo y la bajada del propio medio no lo es.

A24 — título negativo

¡Se terminó! El insólito motivo por el que Karina Jelinek dejó de ser "casi vegana"

BAJADA NEUTRA · Tras años sin consumir carne, Karina Jelinek contó en Puro Show que cambió su dieta por el pádel y que ahora su cuerpo le pide más proteína.

Cebo (clickbait)

Preguntas, exclamaciones, adjetivos exagerados, intriga, segunda persona, listas.

Perfil — 3 recursos de cebo

¿Por qué los manifestantes indios tienen en el punto de mira a la Comisión Electoral?

Transparencia

Notas firmadas por un periodista, según los datos estructurados de la nota.

Misiones Online firmada

Por Karina Gonzalez

Otro medio no cuenta

Por ~~Redacción~~

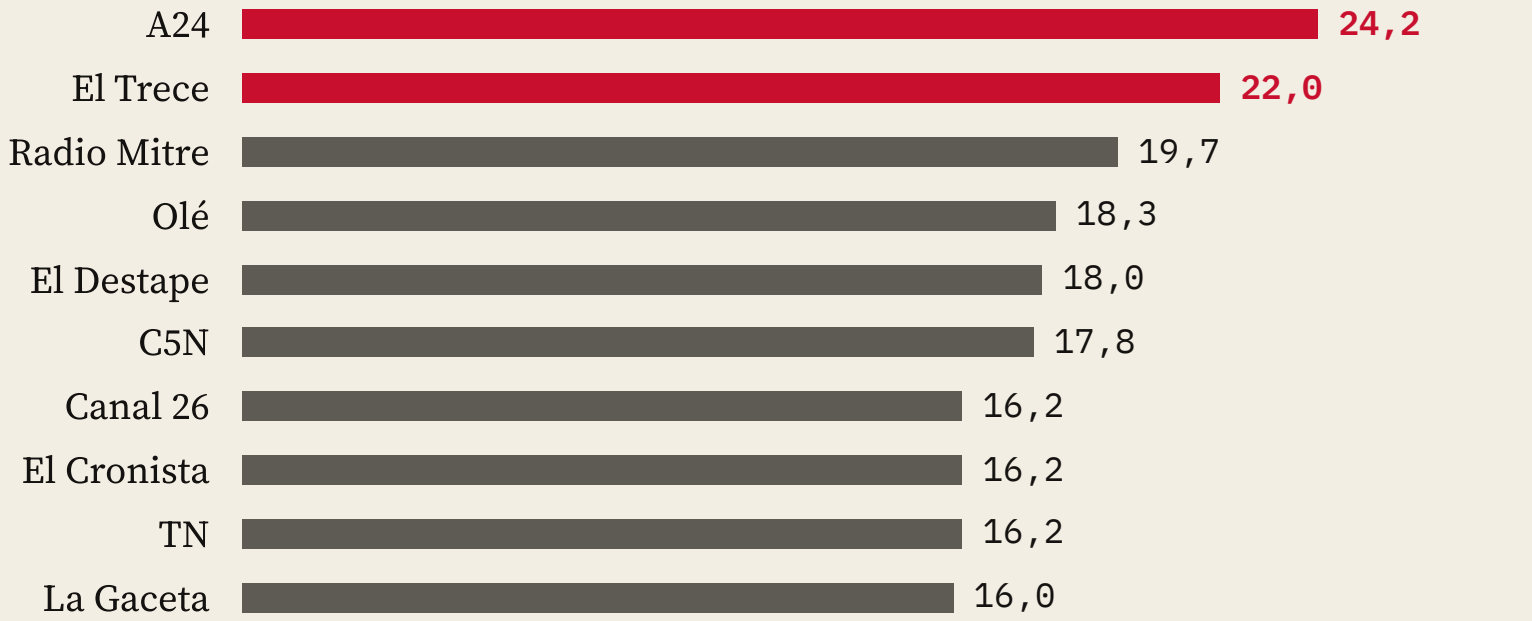
Karina Gonzalez: 199 notas firmadas en Misiones Online, el autor con más notas de la base.

Datos actualizados: 06/11/2026 16:48

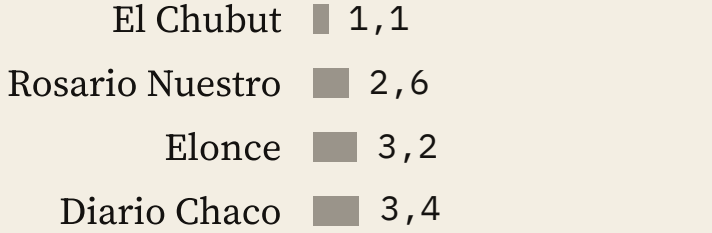
CEBO

A24 y El Trece usan recursos de cebo en casi 1 de cada 4 títulos

TÍTULOS CON AL MENOS UN RECURSO DE CEBO (%)



EN EL OTRO EXTREMO



A24 — últimas 48 h

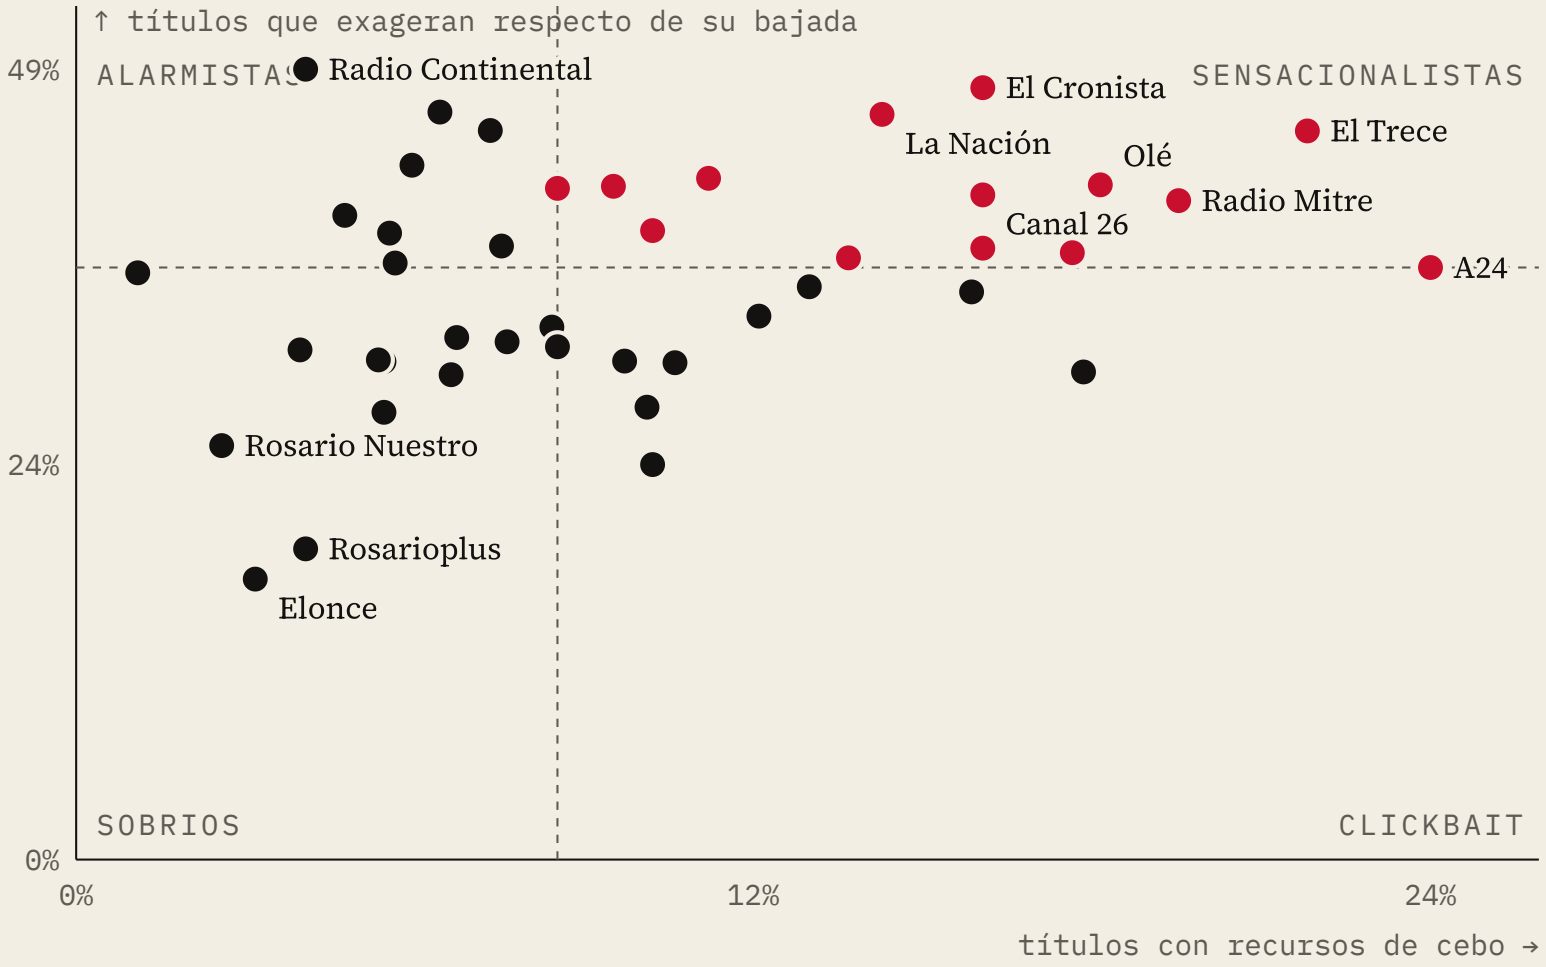
¡Se termino! El insólito motivo por el que Karina Jelinek dejó de ser "casi vegana"

Todo el histórico; medios con 40 notas o más.

Datos actualizados: 06/11/2026 16:48

SENSACIONALISMO

El mapa: quién exagera y quién busca el clic



CÓMO LEERLO

Cada punto es un medio.
Las líneas punteadas son las medianas y dividen el mapa en cuatro estilos.

Sensacionalistas (cebo y exageración): A24, El Trece, Radio Mitre, Olé, El Cronista.

Sobrios: Elonce, Rosarioplus, Rosario Nuestro, El Chubut, La Capital (Mar del Plata).

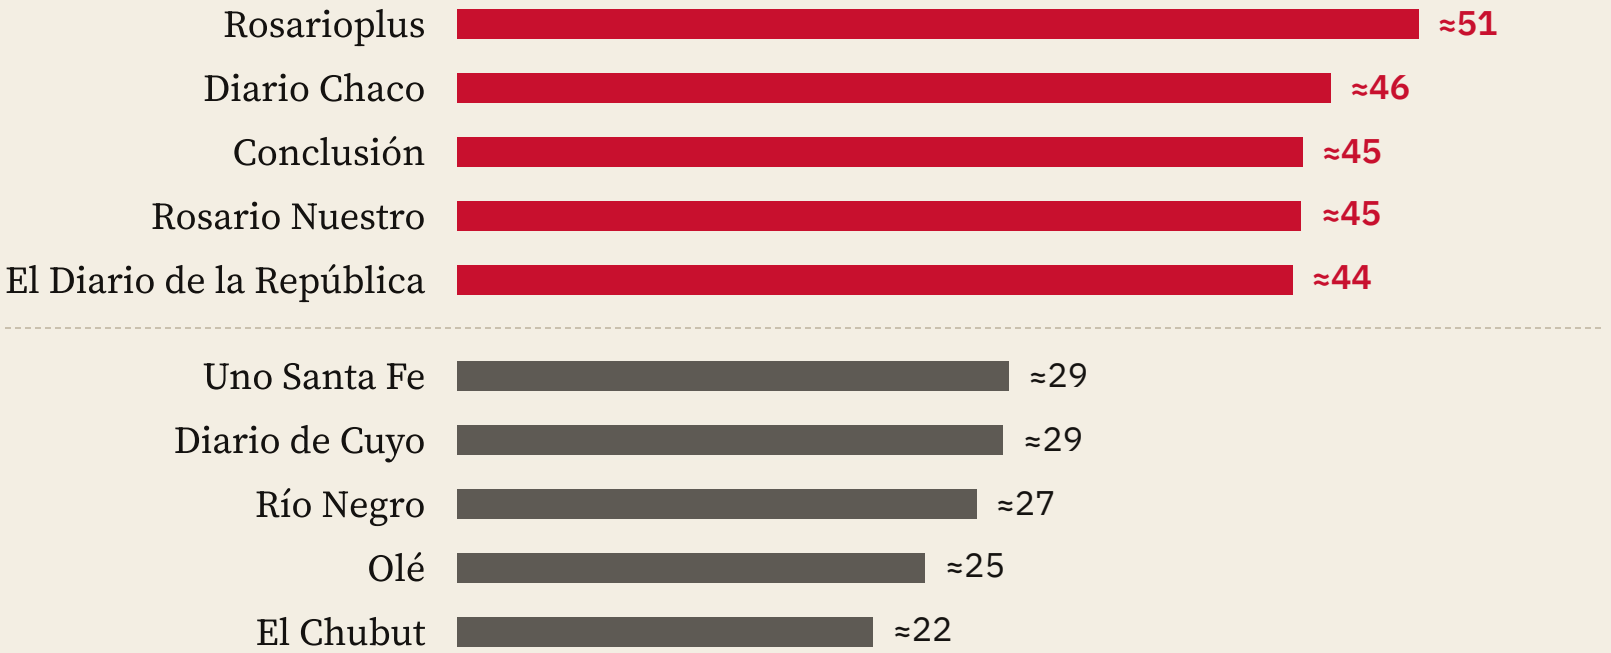
Medición automática con error conocido: sirve para comparar medios, no para juzgar a uno. Todo el histórico.

Datos actualizados: 06/11/2026 16:48

TONO

En Rosarioplus, 1 de cada 2 notas es negativa; en El Chubut, 1 de cada 5

NOTAS CON TONO NEGATIVO (≈ %), LOS 5 MÁS Y LOS 5 MENOS NEGATIVOS



El tono mide si el hecho es bueno o malo, no la postura del medio: quien publica más policiales tiene más notas negativas.

EN TODA LA BASE

37% Negativo

50% Neutro

13% Positivo

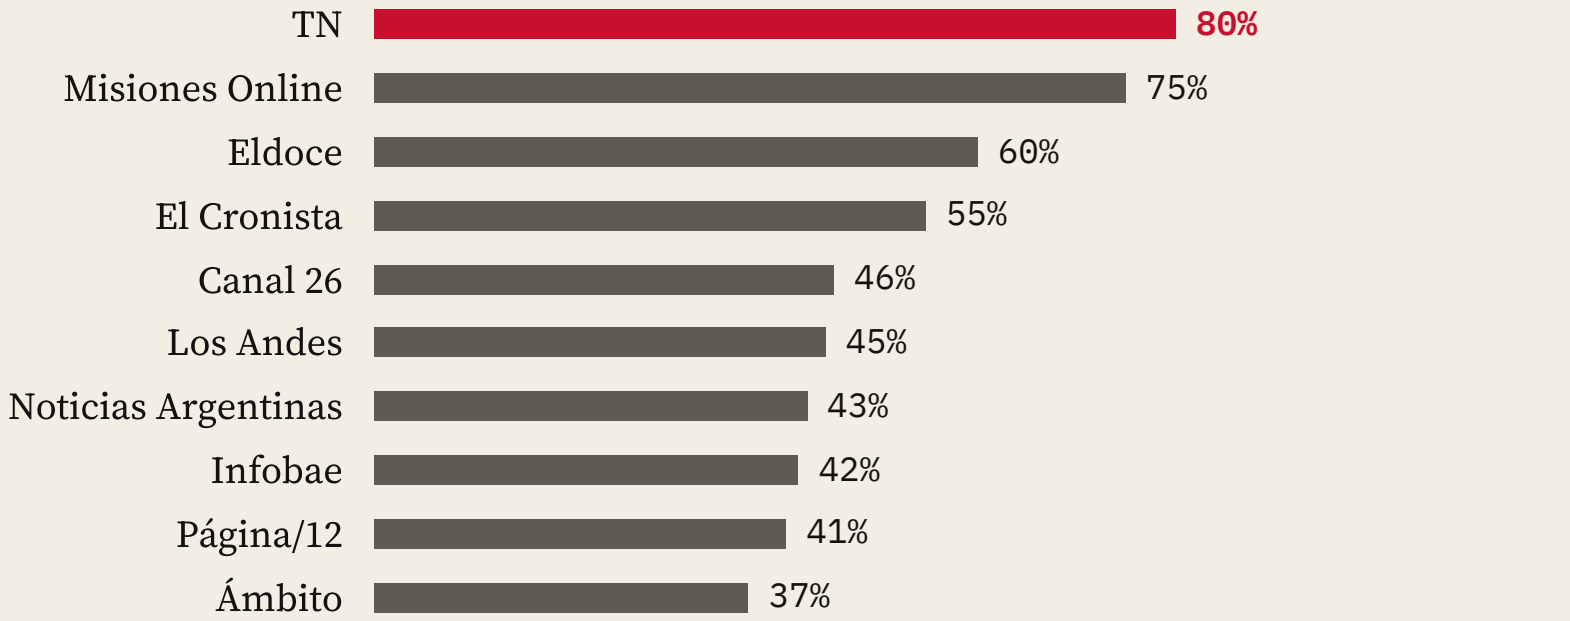
84.302 notas; tono asignado por el modelo combinado, con las etiquetas manuales cuando existen. Barras: medios con 60 notas o más en 30 días, reparto corregido por calibración.

Datos actualizados: 06/11/2026 16:48

TRANSPARENCIA

TN firma el 80% de sus notas; Conclusión y Elonce, ninguna

NOTAS FIRMADAS POR UN PERIODISTA (%)



Según el autor que declara el propio medio en los datos estructurados (JSON-LD). «Redacción» o el nombre del medio no cuentan como firma.

SIN NINGUNA NOTA FIRMADA

- **Conclusión**
- **Elonce**
- **La Capital (Mar del Plata)**
- **Radio Continental**
- **Rosario Nuestro**

Medios con 40 notas o más con datos estructurados; todo el histórico.

Datos actualizados: 06/11/2026 16:48

ENCUADRE · LA NOTICIA MÁS COMPARTIDA

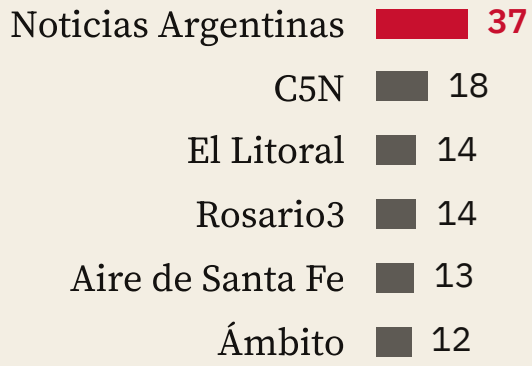
Una noticia, muchos encuadres

11 medios contaron la misma historia. La publicó primero **El Destape** a las 06:11; el último llegó 4 h 14 min después. Títulos: 2 negativos, 4 neutros, 5 positivos; 0 con recursos de cebo, marcados en rojo.

06:11	El Destape primero	TENSO Saludo entre JAVIER MILEI y PEDRO SÁNCHEZ en la Cumbre Iberoamericana	positivo
07:20	Diario de Cuyo +1 h 09 min	Javier Milei y Pedro Sánchez, un saludo frío y fugaz en la apertura del plenario de la Cumbre Iberoamericana	positivo
07:30	C5N +1 h 19 min	Video: el frío saludo entre Javier Milei y Pedro Sánchez en la 30ª Cumbre Iberoamericana	neutro
07:33	La Voz +1 h 22 min	España. Frío saludo entre Milei y Sánchez en Madrid durante la Cumbre Iberoamericana	positivo
08:08	Diario Chaco +1 h 57 min	Milei y Pedro Sánchez tuvieron un frío saludo en la Cumbre Iberoamericana en Madrid	positivo
… y 5 medios más en el medio.			
10:25	Uno Santa Fe +4 h 14 min	Milei en la Cumbre Iberoamericana: frío saludo a Pedro Sánchez, ataque al socialismo y reclamo por Malvinas	negativo

QUIÉN LLEGA PRIMERO

Veces que cada medio publicó primero una historia que después cubrieron otros (48 h).



Datos actualizados: 06/11/2026 16:48

TONO POR FIGURA

Cómo trata cada medio a cada figura

Porcentaje de notas negativas de cada medio cuando menciona a cada figura (últimos 7 días). **Rojo**: más negativo que el promedio de los medios con esa figura; **verde**: menos.

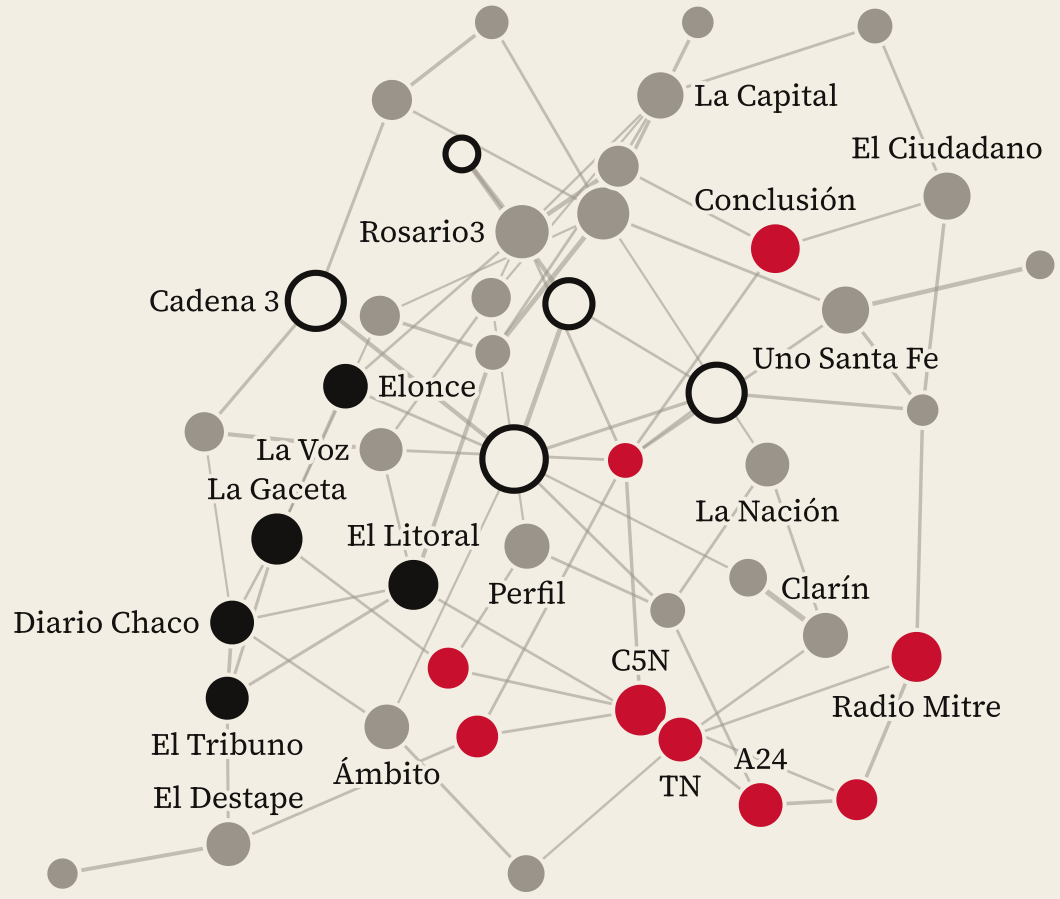
	Papa León XIV	Javier Milei	Donald Trump	River	Boca	Policía
Infobae	17% (237)	30% (85)	47% (215)	24% (39)	22% (49)	63% (146)
Perfil	22% (97)	38% (125)	60% (74)	25% (31)	26% (32)	61% (7)
Clarín	20% (53)	40% (49)	48% (167)	20% (30)	25% (24)	68% (10)
La Nación	19% (96)	42% (60)	48% (58)	19% (51)	19% (35)	82% (11)
TN	19% (53)	33% (43)	48% (30)	28% (54)	15% (62)	78% (17)
Olé	·	·	·	25% (127)	21% (105)	·
Cadena 3	13% (58)	29% (25)	36% (31)	21% (43)	17% (36)	73% (8)
El Destape	17% (33)	41% (83)	53% (32)	33% (25)	34% (21)	·

Solo celdas con 3 notas o más; entre paréntesis, la cantidad de notas. Con pocos días los valores son ilustrativos: muestran el método.

Datos actualizados: 06/11/2026 16:48

MINERÍA DE ESTRUCTURA

El mapa de medios: quién comparte agenda con quién



COMUNIDADES DETECTADAS

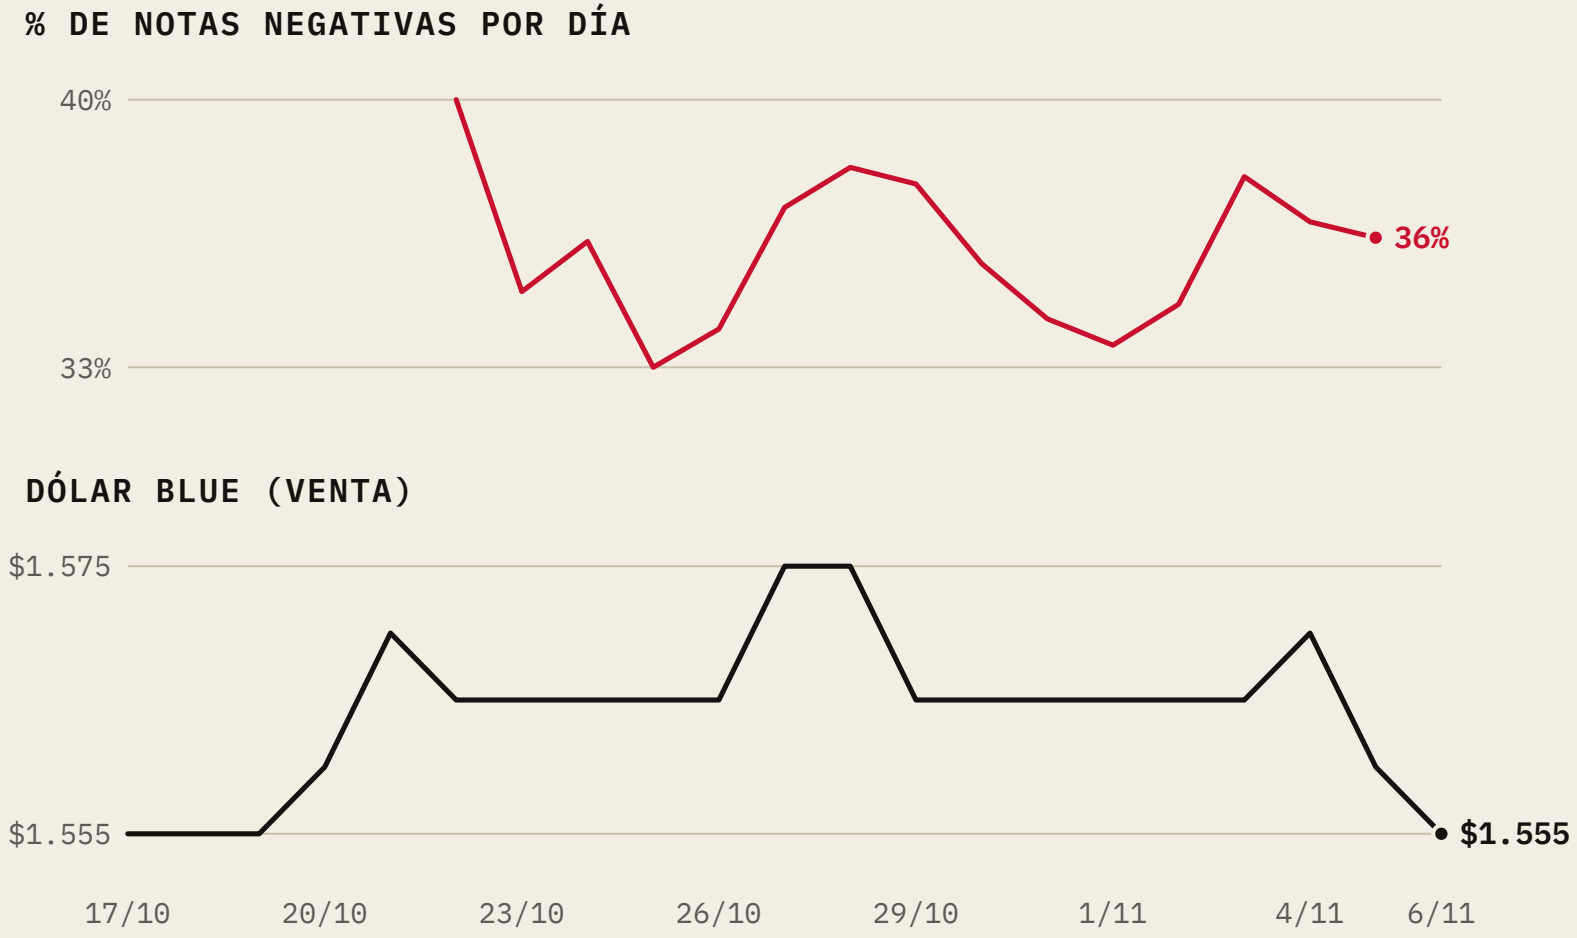
- **Comunidad 1:** A24, C5N, Canal 26, Conclusión, Diario de Cuyo, El Día (La Plata), El Trece, Radio Mitre, TN
- **Comunidad 2:** Diario Chaco, El Litoral, El Tribuno, Elonce, La Gaceta
- **Comunidad 3:** Cadena 3, El Chubut, La Capital (Mar del Plata), La Nueva (Bahía Blanca), Noticias Argentinas
- **Otros 26 medios**, sin una comunidad propia

Una línea une a dos medios que cubren las mismas historias (48 h); cada medio conserva sus 3 vínculos más fuertes. Tamaño: historias compartidas.

Datos actualizados: 06/11/2026 16:48

CLIMA MEDIÁTICO Y DÓLAR

¿El tono de las noticias acompaña a la economía?



LECTURA

En el período, el blue pasó de $1.555 a **$1.555** (+0,0%).

r = -0,18

entre el % de notas negativas y la variación diaria del blue (15 días): sin relación clara.

Correlación no implica causalidad. Dólar: argentinadatos.com y dolarapi.com.

Datos actualizados: 06/11/2026 16:48

EL TABLERO Y LA DEMO

Todo esto, en un tablero público que se consulta con SQL

EL TABLERO, EN VIVO

miguegarrone-blip .github.io/Web-Mining

Resumen, titulares con buscador por significado, monitor de figuras, análisis, cómo titulan, tendencias y salud de datos. Funciona en el celular.

ABRIR EL TABLERO

CORRER LA CONSULTA

DEMO: LA BASE EN EL NAVEGADOR (DATASETTE LITE, TABLA NOTAS)

```
SELECT medio,
  ROUND(100*AVG(cebo>=1), 1) AS cebo,
  ROUND(100*AVG(tono='n'), 1) AS neg
FROM notas
GROUP BY medio
HAVING COUNT(*) >= 50
ORDER BY cebo DESC;
```

SQLite corre en el navegador con WebAssembly: no hay que instalar nada. explorar.db trae los últimos 7 días; la base completa se descarga desde el tablero.

FICHA TÉCNICA

Staff: un stack simple, gratuito y reproducible

RECOLECCIÓN	requests · feedparser · googlenewsdecoder · urllib.robotparser
EXTRACCIÓN	expresiones regulares · JSON-LD (schema.org) · HTML
LENGUAJE	bolsa de palabras · Naive Bayes · regresión logística · XLM-RoBERTa · MiniLM · spaCy (NER)
DATOS	SQLite · CSV · Datasette Lite · notebook con pandas
AUTOMATIZACIÓN	GitHub Actions cada 30 minutos (autodisparo) · pruebas automáticas
VISUALIZACIÓN	HTML, CSS y JavaScript sin frameworks · GitHub Pages · esta presentación

CONTRATAPA · PROBALO AHORA

Gracias

Escaneá el código para abrir el tablero y consultar la base con SQL.

miguegarrone-blip.github.io/Web-Mining

Grupo 3: Martín Ceriotti · Miguel Garrone · Lucía Tamplin · Milagros Terán

Código: github.com/miguegarrone-blip/Web-Mining

Datos actualizados: 06/11/2026 16:48